

基于多智能体意图建模的人群出行行为 涌现机制分析

Research on traditional cross talk based on Guankou

一级学科： 计算机技术

研究方向： 群体智能

作者姓名： 沈逸帆

指导教师： 薛霄

答辩日期	20 年月日		
答辩委员会	姓名	职称	工作单位
主席			
委员			

天津大学计算机科学与技术学院
二〇二一年九月

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 天津大学 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名： 签字日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解 天津大学 有关保留、使用学位论文的规定。特授权 天津大学 可以将学位论文的全部或部分内容编入有关数据库进行检索，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。

(保密的学位论文在解密后适用本授权说明)

学位论文作者签名： 导师签名：

签字日期： 年 月 日 签字日期： 年 月 日

摘要

随着互联网、物联网与社交媒体的发展，城市人群出行行为的交互规模与复杂性不断提升，涌现出交通拥堵、内卷竞争等群体现象。此类现象难以仅通过行为结果层面的统计分析揭示其内在涌现机制。基于智能体的计算实验方法能够将现实城市人群映射为计算机中可计算并重现的人工社会模型，为量化分析涌现的机制提供数字化和计算化的方法。然而，现有方法在模拟过程中聚焦于行为生成与轨迹拟合，缺乏对出行意图形成过程的建模，进一步限制了对涌现现象的机制分析。为此，本文以智能体出行意图为核心，构建模拟与机制分析的统一框架。具体而言，本文开展了以下研究工作：

(1) 针对现有模拟方法缺乏认知意图建模的问题，本文提出了基于智能体意图建模的城市人群出行行为模拟方法。该方法首先通过监督微调与直接偏好优化相结合的两阶段训练对大语言模型进行对齐，利用基于真实轨迹构建的情景化偏好数据增强其在出行情景下生成结构化意图推理链的能力，使智能体能够依据状态与感知信息形成可解释的出行意图。在此基础上，在智能体个体层面构建认知意图模块，通过结构化推理生成出行意图，并在引力模型框架下完成空间选择与行为执行。人群出行行为模拟实验结果表明，该方法在保证轨迹统计合理性的同时，提高了意图生成的准确度，并在群体层面形成与真实历史数据相一致的涌现特征。

(2) 针对现有出行行为分析方法难以从意图层面开展机制分析的问题，本文构建了一种基于意图的人群出行行为涌现机制分析方法。该方法以个体层面的认知意图为分析核心，通过聚类刻画群体中意图状态的分布特征，之后通过马尔科夫建模群体智能体意图的时序演化过程，构建意图状态与后续行为决策之间的条件概率映射，并分析意图演化过程与宏观涌现指标变化之间的协同演化关系。基于城市人群出行行为涌现现象的实验分析结果表明，该方法能够有效揭示群体行为涌现的内在意图驱动过程，提升了涌现现象分析的机制解释能力。

在上述方法基础上，本文构建了基于智能体意图建模的城市人群出行行为模拟与机制分析系统，实现从认知意图生成、行为模拟到群体涌现机制分析的统一框架，从而为城市人群出行行为涌现现象的机制研究提供新的计算实验方法。

关键词：计算实验，人工社会建模，认知意图建模，多智能体，涌现分析

ABSTRACT

With the rapid development of the Internet, the Internet of Things, and social media, human behavior has exhibited increasingly diverse and complex patterns, giving rise to collective phenomena that are difficult to explain using surface-level behavioral statistics alone. Agent-based computational experiments, which simulate and analyze human behavior, are undergoing a paradigm shift toward large language model-driven approaches, providing powerful tools for studying such complex systems. However, accurately analyzing the cognitive mechanisms underlying collective behavior remains a major research bottleneck. Existing models of Agent behavior often overlook anthropomorphic characteristics such as bounded rationality, resulting in simulations that are confined to reproducing observable behaviors and fail to further explain how individual Agent decisions give rise to macroscopic emergent phenomena. Motivated by this limitation, this paper takes individual Agent intentions as a unified modeling object and aims to construct an integrated analytical framework that links micro-level individual intentions to macro-level collective evolution, thereby enhancing the interpretability and predictive capability of complex social system simulations. Specifically, this work makes the following contributions:

(1) To address the lack of intrinsic cognitive alignment in existing human behavior simulation models, we propose a dual-layer intention-driven Agent cognitive modeling approach based on experience and reasoning. First, a Direct Preference Optimization (DPO) algorithm is introduced to align the model through learning human decision-making preferences, enabling Agents to dynamically adjust the weighting between the two layers according to environmental states and to adaptively generate intention strategies that conform to human behavioral logic. Second, grounded in bounded rationality theory, we design a comprehensive cognitive architecture that integrates attribute profiles, memory retrieval, environmental perception, and reasoning interactions, thereby constructing a dual-layer intention generation mechanism in which intuitive experience and deliberative reasoning operate in parallel. Finally, a city-scale mobility simulation environment is built using large-scale real-world trajectory data, and behavior decision tasks are conducted under various complex interaction scenarios. Experimental results demonstrate that the proposed model significantly outperforms existing baseline meth-

ods in terms of intention prediction accuracy and generalization in long-tail scenarios, effectively enhancing the human-likeness of Agent behaviors.

(2) To overcome the limitation of existing analyses of collective Agent emergence that focus solely on behavioral outcomes, we further develop an intention-based collective Agent mechanism analysis framework. This framework bridges micro-level individual cognition and macro-level collective phenomena by systematically aggregating individual Agent intentions and combining state clustering with Markovian dynamical modeling to characterize temporal intention transition processes. Moreover, the dynamic relationship between intentions and behaviors is explicitly decomposed and quantitatively analyzed. Compared with traditional behavior-centric analysis methods, the proposed framework establishes a unified modeling paradigm that progresses from micro-level intention representations to the interpretation of macro-level emergent mechanisms. Experimental results based on an urban traffic simulation system demonstrate that this approach more effectively traces the intrinsic driving forces behind collective behavioral emergence and substantially improves the interpretability of urban traffic simulations.

KEY WORDS: Keyword, Keyword, Keyword, Keyword, Keyword

目 录

第 1 章	绪论	1
1.1	研究背景与意义	1
1.2	国内外研究现状	4
1.2.1	城市人群出行行为模拟研究现状	4
1.2.2	城市人群出行行为的机制分析研究现状	5
1.2.3	存在的挑战与不足	6
1.3	研究问题	7
1.4	研究思路与创新	8
1.4.1	研究思路	8
1.4.2	论文主要创新点	9
1.5	研究内容与组织结构	10
1.5.1	研究内容	10
1.5.2	组织架构	11
1.6	本章小结	12
第 2 章	理论研究与相关方法	13
2.1	计算实验	13
2.2	城市人群移动行为模拟方法	15
2.2.1	知识驱动的模拟方法	16
2.2.2	数据驱动的模拟方法	17
2.2.3	意图驱动的模拟方法	18
2.3	涌现分析理论	20
2.3.1	复杂系统的涌现	20
2.3.2	涌现分析方法	21
2.4	大语言模型相关理论	23
2.5	本章小结	24
第 3 章	基于 Agent 意图推理模型的城市人群出行行为模拟方法	25
3.1	问题描述	25
3.2	基于 Agent 意图建模的城市人群移动行为模拟框架	26
3.2.1	情景记忆模块	27
3.2.2	认知意图模块	29

3.2.3	模型训练方法	31
3.2.4	数据构建流程	32
3.3	模拟整体流程	34
3.3.1	离线训练阶段	34
3.3.2	在线执行阶段	35
3.4	实验评估	36
3.4.1	实验设置	36
3.4.2	实验分析	42
3.5	本章小结	50
第 4 章	Agent 意图推理驱动的人群出行行为涌现机制分析方法	51
4.1	问题描述	51
4.2	基于意图模型的群体 Agent 机制分析方法框架	52
4.2.1	群体意图提取	53
4.2.2	意图聚类抽象	55
4.2.3	时序演化分析	57
4.2.4	涌现机制分析	59
4.3	实验系统构建	60
4.4	实验设计与结果分析	62
4.4.1	实验设计	62
4.4.2	实验分析	64
4.5	本章小结	74
第 5 章	城市人群移动行为涌现机制分析系统	75
5.1	需求分析及开发环境	75
5.2	系统架构设计	76
5.3	系统运行流程	77
5.4	系统效果展示	78
5.5	本章小结	80
第 6 章	总结与展望	81
6.1	论文总结	81
6.2	展望	82
参考文献		83
发表论文和参加科研情况说明		89
致 谢		91

第1章 绪论

本章首先对本文的研究背景进行详细介绍，并结合国内外研究现状，分析已有问题与挑战，从而引出本文的研究问题。针对研究问题提出了本文的研究思路与创新点，接着对研究内容进行总结，并介绍了本文的组织架构。

1.1 研究背景与意义

随着互联网、物联网、大数据及社交媒体技术的快速发展，城市人群出行行为日益呈现出高度的开放性、交互性与非线性特征，逐渐演化为典型的复杂社会系统。个体出行决策在多主体互动与制度约束下不断叠加，涌现出交通拥堵、资源竞争加剧等一系列宏观现象。理解此类现象的形成机制，不仅需要刻画出行行为的统计规律，更需分析个体决策在群体层面放大与演化的内在机制。相关研究表明，基于复杂性科学构建的建模与分析方法已成为解析社会动态的重要工具，并在城市风险预警、公共安全治理及社会系统调控等领域展现出广泛应用潜力。

然而，面对城市人群出行行为这一高度复杂且不可还原的社会系统，现实世界中的干预实验往往受到实验成本、伦理规范及法律约束的限制，使得仅依赖传统实证分析难以深入揭示其内在决策机制。在此背景下，研究范式逐步转向以计算实验为核心的方法体系。如图 1-1 所示，计算实验采用自底向上的方法，利用




图 1-1 计算实验方法图

分散的微观智能模型来模拟真实世界中各类实体的微观行为,再通过设计这些个体间的相互作用形成复杂的现象,从而反映整个系统在宏观层面的演化规律。因此,计算实验的有效性在很大程度上取决于其对个体决策生成机制的刻画能力。

在城市人群出行行为研究中,个体轨迹与活动序列并非对环境刺激的被动响应,而是由其内在目标、偏好与情境判断共同驱动的决策结果。近年来,随着大语言模型 (Large Language Model, LLM) 在语义理解与情境推理方面能力的提升,相关研究开始尝试利用其生成更具灵活性与情境适应性的个体行为规划,从而在人群出行模拟中个体的出行行为层面提升模拟结果的多样性与合理性,但这类方法仍主要停留在行为结果层面的对齐,缺少移动行为所需的意图推理建模,引入意图建模能够使个体在不同情境下的出行选择更加符合其出行目标、情境判断与行为动机,从而更接近真实人类的决策过程,另一方面针对模拟出的涌现现象需要基于意图作为行为机制分析的依据,分析人群中个体行为的生成规则和人群间行为的互动规则以及涌现出特定宏观结果的内在机制。

现有研究在普遍将关注点停留在对齐行为本身,主要通过对轨迹分布、空间覆盖范围或统计指标的匹配程度来评估模型性能,而缺乏对移动行为生成过程中内在意图动机的刻画与分析。在此框架下,个体的出行决策背后的目标取向、风险权衡或主观判断难以被区分与解释,导致模型虽能模拟移动行为,却难以模拟移动行为的意图动机。针对人群移动行为的机制分析,传统的方法通常基于大规模行为数据提取统计模式,核心目标在于对行为的分析难以揭示从情景变化到宏观结果之间的演化过程。基于行为的机制分析强调从个体行为动机出发,刻画信念、目标与意图等内部属性对行为生成的影响,并进一步分析人群主体间互动规则如何在系统层面累积并形成宏观结构,从而实现对涌现现象的机制解释。尽管该行为机制分析增强了行为分析的表达能力,它仍未对意图本身的生成过程进行建模,也无法解释个体内在认知动态如何随时间演化,或如何在群体中相互作用。缺乏对意图生成、选择及其随时间演化过程的系统建模,使得研究难以进一步分析不同认知取向在群体层面如何通过个体交互产生结构性差异,从而限制了对宏观出行模式及其异常涌现现象的机制性解释,主要表现在以下两个方面:

1) Agent 的出行行为缺乏可解释的决策建模:现有基于 Agent 的城市人群出行行为模拟方法主要围绕行为轨迹的对齐与生成展开,其建模重点在于利用当前时空状态预测个体的下一步位置或行动选择,而对行为背后所驱动的人类认知与意图演化过程关注不足。此类方法往往将 Agent 视为对外部状态作出被动响应的决策单元,训练目标集中于行为结果的拟合,而非对意图动机的学习与约束。部分研究虽然在模型结构中引入了意图模块或决策规则,但其训练目标并未与相应的认知假设形成一致化设计,导致模型学习到的行为模式与预设的意图动机之间存在脱节,难以刻画个体在决策过程中意图状态的动态变化。另一方

面，现有模型普遍缺乏具有人类特征的意图推理机制，难以刻画个体在不同情境下的意图推理过程，缺乏可解释性。

2) 缺乏基于意图的机制分析：现有基于 Agent 的城市人群移动模拟研究虽能够在仿真环境中生成涌现现象，但在此基础上缺乏对其形成机制的系统分析，缺乏从个体决策与认知意图演化角度展开的机制性解释。具体而言，现有模型往往缺乏对从意图到行为再到涌现这一跨尺度演化过程的显式建模与定量分析工具，使得微观意图如何经由 Agent 间交互与环境反馈逐步放大、耦合并最终表现为宏观群体移动性现象。

应对上述挑战，有必要通过意图建模推进城市人群移动行为模拟到分析的研究工作。首先，需要在个体层面显式建模 Agent 的移动认知意图，使微观决策不再仅表现为对环境刺激的行为响应，而是反映其内在目标、经验依赖与推理权衡过程；在此基础上，进一步围绕这些认知意图构建群体层面的机制分析方法，解析意图在个体交互中的演化、聚合与演化机制，从而解释宏观出行模式及其涌现现象的形成过程。

基于认知心理学与行为科学的广泛研究共识，人类行动并非始终由统一的理性决策机制所支配，而是呈现出显著的双系统控制特征。Kahneman 等人提出的双系统理论^[1]指出，个体在决策与行动中同时受到经验驱动的自动化加工系统与推理驱动的审慎加工系统影响；后续研究表明，这种认知划分不仅存在于抽象判断任务中，也广泛体现在现实世界的行为决策过程中。在出行与旅游决策领域，已有实证研究验证了上述双系统特征^[2]：在熟悉、低参与度的日常出行情境中，个体往往依赖基于过往经验的快速信息处理与行动模式；而在陌生、高不确定性或高重要性的出行决策中，个体则更倾向于投入认知资源，对候选方案进行权衡与推理分析。这些研究表明，人类出行行为本身即表现出在经验型与推理型控制之间动态切换的倾向，而非始终遵循完全理性的最优规划。

基于双系统决策理论，本文将 Agent 个体意图作为核心建模对象，并将意图生成机制设计为分阶段推理结构：在经验匹配充分的情境下执行基于经验的快速决策，而在情境复杂或经验不足时启动基于情境信息的审慎推理过程，以生成结构化的行动意图。在此框架下，本文基于真实历史移动轨迹数据构建结构化意图训练样本，并结合人类偏好优化方法对大语言模型进行对齐，使 Agent 在不同情境条件下生成结构化意图推理链，并在此基础上完成移动决策与行为执行。在分析层面，本文进一步将研究对象上移至意图演化过程，构建基于意图的群体机制分析方法，以揭示微观认知如何通过个体交互与环境反馈演化为宏观群体移动模式。本文的研究课题兼具理论深度与现实意义，具体如下：

1) 理论意义：对城市人群出行行为的研究本质上是一个高度复杂且充满不确定性的过程，其不确定性来源于个体行为的异质性、情境感知的动态变化以及

多主体交互所涌现的现象。若仅基于历史轨迹数据进行模式拟合，模型往往只能复现既有出行结果，而难以刻画轨迹生成背后的认知决策机制，从而限制了对行为成因的解释能力，也难以支持对出行行为进行有针对性的反事实干预与情景推演。本文从计算实验与人工社会建模的视角出发，对城市人群出行行为模拟框架引入具有认知深度的意图演化机制，提高行为轨迹的可解释性。同时，本文进一步提出了基于意图的从微观意图状态到宏观群体涌现现象的全过程分析范式，弥补了现有研究中重现象、轻机制的不足，为群体涌现行为解释以及社会系统涌现机制研究提供了新的方法论支撑，对复杂社会系统建模与分析理论具有一定的推进作用。

2) 现实意义：在现实应用层面，本文所提出的基于认知意图驱动的群体移动建模与分析框架，可为城市交通治理、公共政策评估及智能交通系统设计提供更具解释力与前瞻性的决策支持。相较于仅依赖历史轨迹复现的传统模型，该方法能够更真实地反映个体在不同情境与交互条件下的决策逻辑，从而提升对非平稳环境与突发情形的模拟与预测能力。通过揭示群体移动性现象背后的意图演化与交互机制，本文有助于政策制定者理解拥堵、竞争等宏观问题的深层成因，为交通引导策略优化、资源配置调整及风险预警提供依据，具有重要的工程应用价值与社会现实意义。

1.2 国内外研究现状

1.2.1 城市人群出行行为模拟研究现状

早期针对城市人群出行行为模拟的研究主要采用基于模型原理的传统建模方法，其核心思想是将个体历史轨迹与未来运动状态之间的关系形式化为可解析的概率或动力学问题。代表性工作包括基于物理与统计力学假设的社会力模型，其中 Helbing 等人通过引入引力与斥力刻画行人间交互行为，为密集人群场景下的轨迹建模提供了经典范式^[3]。此外，Wiest 等人、Lim 等人以及 Wang 等学者分别将高斯混合模型、高斯过程回归及高斯过程动力学模型引入轨迹预测任务，用以描述非线性运动模式^[4,5]。此类方法具有良好的可解释性与物理一致性，但往往依赖强先验假设，难以刻画复杂社会交互与异质个体行为，在泛化能力与预测精度方面存在明显局限。

随着深度学习的发展，数据驱动方法逐渐成为人类移动轨迹预测研究的主流方向。循环神经网络 (RNN) 及其变体长短期记忆网络 (LSTM) 因其对时序依赖关系的建模能力，被广泛应用于轨迹预测任务^[6]。Alahi 等人提出的 Social-LSTM 首次将行人之间的社会交互关系纳入序列建模框架，通过社交池化机制显著提升

了预测性能^[7]。在此基础上, 后续研究进一步融合场景语义、群体状态以及多模态交互信息, 提出了 SS-LSTM、SR-LSTM 等改进模型^[8,9]。为进一步缓解序列建模能力与交互表达的限制, 生成模型与图结构建模方法也被引入轨迹预测领域。基于 GAN 与 CVAE 的方法通过显式建模轨迹分布, 提高了多模态预测能力与不确定性表达水平^[10-12]; 同时, 图神经网络 (GNN) 与时空图模型被用于刻画行人之间复杂的交互关系, 通过构建时空图或引入图注意力机制, 实现对群体行为结构的建模^[13]。近年来, Transformer 结构凭借其全局依赖建模能力与并行计算优势, 也逐渐成为轨迹预测的重要技术路线, 如 TransformerTraj、TUTR 以及多种时空 Transformer 模型^[14,15]。

近年来, 大语言模型 (Large Language Model, LLM) 的兴起为人类出行轨迹建模提供了新的研究范式。相关研究开始探索将 LLM 的语言理解与推理能力引入移动轨迹预测与分析任务, 尝试将轨迹预测问题重构为语言推理或问答问题, 从而利用语言模型在复杂语义理解与知识表达方面的能力^[16,17]。在这一研究方向中, 一类方法通过时空编码与表示对齐机制, 使语言模型能够处理城市移动数据。UrbanGPT^[18] 与 Time-LLM^[19] 通过将时空信息嵌入语言模型表示空间, 从而在数据稀疏或复杂环境下提升预测性能。在此基础上, 一些研究进一步在 LLM 框架中引入行为语义与意图信息, 以增强模型对个体移动行为的表达能力。Mobility-LLM^[20] 通过语义重编程与偏好建模机制, 使模型能够从轨迹数据中提取潜在出行意图, 从而提升对行为语义的刻画能力。进一步地, 部分研究结合心理学与行为科学理论, 对个体决策过程进行建模。例如 CoPB^[21] 将计划行为理论嵌入语言模型推理链条, 实现意图生成与空间路径规划之间的映射关系。此外, Ge 等人^[22] 通过构建认知结构并结合模型微调训练, 将数据驱动方法与意图驱动建模相结合, 为城市人群出行行为模拟提供了新的研究思路。

1.2.2 城市人群出行行为的机制分析研究现状

在人类出行系统中, 大量个体在有限理性与局部信息约束下进行决策与交互, 其集体行为往往呈现出显著的涌现特征。涌现^[23] 是指宏观层面的有序结构、统计规律或突发模式并非由任何单一个体直接设计, 而是由个体间的非线性交互自发形成。在出行与交通研究中, 典型的涌现现象包括交通拥堵的自发形成与传播^[24]、行人流的相变与瓶颈效应^[25]、出行需求的时空集聚^[26]、以及平台经济场景下的恶性竞争与内卷化行为^[27] 等。这类现象通常具有突发性、非平稳性与路径依赖性, 仅通过微观行为的简单叠加难以解释, 其形成机理长期以来是交通科学与计算社会科学关注的核心问题。

针对人类出行涌现现象的分析, 早期研究多采用基于统计物理与复杂网络的宏观建模方法。Kerner^[28] 等人通过相变理论刻画交通流由自由流向拥堵态的

跃迁过程，揭示了拥堵形成的非线性本质；Helbing^[3] 等人利用流体动力学与社会力模型分析行人群体中的自组织现象，如车道化与振荡流动。这类方法在揭示整体规律方面具有优势，但通常依赖理想化假设，难以反映真实个体决策差异及动态适应行为。随后，复杂网络分析被广泛用于刻画出行系统的结构特征与演化规律，通过构建 OD 网络^[29]、接触网络或多层交通网络^[26]，研究者分析了网络连通性、中心性及鲁棒性对宏观出行模式的影响。

随着微观数据可获得性的提升，基于 Agent 的建模方法 (ABM)^[30] 的涌现分析逐渐成为主流研究范式。相关研究通过构建具有简单决策规则的移动 Agent，模拟个体在局部交互与环境约束下的出行行为，并观察群体层面涌现出的宏观模式。Nagel^[31] 等人提出的 MATSim 框架，通过大量个体的路径选择与学习行为，成功复现了交通流的日常演化特征；Batty^[32] 等人从城市复杂系统视角出发，系统分析了微观出行行为如何塑造城市尺度的空间结构。这类方法为从微观到宏观的机制分析提供了有效工具，但在实际应用中，Agent 决策规则往往被简化为启发式或经验公式，导致涌现结果对参数高度敏感，解释性与可迁移性受到限制。

在机制分析方法层面，现有关于人群移动行为涌现现象的研究通常从宏观统计分析、中观结构动力学以及微观行为机制三个层面展开。在宏观层面，研究主要通过对出行距离分布、停留时间分布、访问频率以及 OD 流网络等统计指标进行分析，以揭示城市移动行为所呈现的重尾分布特征、跨尺度统计稳定性以及周期性结构等宏观规律^[33,34]。此类方法能够从整体层面刻画人群移动行为的结构特征，但其研究重点主要集中于对系统结果的统计描述与模式识别。

在中观层面，研究重点转向群体交互结构与组织机制，通过构建事件结构或情景网络，刻画个体交互规则在组织层面的扩散与协同过程，并利用马尔可夫过程、主方程及谱分析等动力学工具研究系统状态在时间与状态空间中的演化路径^[35]。在微观层面，以 Agent 建模为核心，通过强化学习、进化机制或模仿学习等方式刻画个体行为生成与更新过程，从而分析微观决策规则如何在主体交互中逐步累积并形成宏观群体结构^[36]。近年来，一些研究进一步结合概率因果模型与反事实推断方法，对不同情景变量之间的因果关系进行量化刻画，从而增强对复杂系统涌现机制的解释能力^[37]。

1.2.3 存在的挑战与不足

现有城市人群移动行为研究虽在行为复现与宏观现象刻画方面取得了一定进展，但在机制层面仍存在明显不足。一方面，基于历史轨迹的数据驱动方法能够较好地拟合既有出行模式，却难以揭示轨迹生成背后的认知决策过程；另一方面，分析方法多停留在宏观统计或宏观分析层面，微观个体的意图、行为与涌现的宏观现象之间缺乏可解释的机制分析方法。

在微观建模层面，现有城市人群出行行为模拟方法仍缺乏具有认知深度的意图演化建模机制。现有研究中，传统的基于 Agent 的建模方法以及近年来引入大语言模型的 Agent 框架，多数侧重于行为轨迹生成的合理性与多样性，而对个体在有限理性约束下基于经验积累与情境理解形成的结构化意图推理机制缺乏系统刻画，从而导致行为生成过程的可解释性不足。

在机制分析层面，现有研究多侧重于对群体行为结果的统计分析或结构刻画，缺乏从个体认知意图出发解释群体涌现现象的分析框架。多数方法主要基于宏观交通流指标或群体结构特征进行模式识别与统计拟合，难以揭示个体行为产生的认知动因及其在主体交互中的演化过程。因此，宏观现象虽然能够被准确模拟，但其形成机制难以从微观行为生成逻辑进行解释，复杂的群体涌现现象也难以得到清晰的机制说明。如何在保持模型可扩展性的同时，将个体认知意图的演化过程与宏观群体结构变化相结合，构建以意图为核心的机制分析框架，仍是当前研究亟待解决的关键问题。

1.3 研究问题

城市人群出行行为是个体认知、决策与社会交互共同作用下形成的时空行为结果，并在时间演化过程中不断涌现出显著的异质性、不确定性与涌现性特征。从宏观层面看，人群出行模式呈现出拥堵、集聚、竞争与协同等复杂现象；而从微观层面看，这些现象并非由简单的物理约束或统计规律直接决定，而是源于大量个体在特定情境下，基于自身经验、环境感知与社会规范生成认知意图，之后做出出行决策。然而，现有以历史轨迹拟合或行为复现为核心的研究范式，往往侧重于结果层面的群体现象重现，难以模拟轨迹生成背后的出行意图，从而缺乏对个体决策如何经由交互与演化机制涌现为宏观出行模式的系统性解释。这一可模拟而不可解释的矛盾，构成了当前人类出行建模与分析研究中的关键瓶颈。在此背景下，本文关注的核心科学问题是：如何通过构建可解释的个体意图模型，以模拟微观出行决策的认知合理性，进一步揭示其在群体层面上演化为人群出行行为涌现模式的内在机制。围绕上述矛盾，本文聚焦于以下两个相互关联且层次递进的研究问题：

(1) 如何构建具有人类认知特征的出行 Agent 意图模型，以真实刻画群体出行移动行为的生成机制？人群出行决策并非单纯由即时刺激或历史统计模式驱动，而是体现了经验积累、情境判断与推理调节相结合的拟人化特征。现有人群 Agent 模型多以出行轨迹模拟为主，缺乏对出行意图这一中间认知层的显式建模，难以解释个体为何在相似环境下作出不同出行选择，也难以在长周期或复杂交互条件下保持行为一致性。因此，有必要探索能够刻画城市人群移动意图形成

与演化过程的建模方法，使个体轨迹生成具备明确的意图推理过程，从而提升出行模拟在真实性与稳定性方面的表现。

(2) 如何从微观出行意图的出发，系统性揭示群体出行涌现现象的机制？群体尺度的出行现象本质上源于大量个体意图与行为在交互网络中的非线性耦合，但现有研究多停留在宏观指标拟合或统计关联分析层面，缺乏从意图到涌现现象的跨尺度因果链条的刻画。微观个体的出行意图如何在交互过程中相互影响、聚合与重构，并最终涌现为可观测的群体移动模式，仍缺乏系统性的分析框架。因此，亟需建立一种以个体意图状态为核心变量的群体分析范式，用以连接微观认知演化与宏观出行现象，从而实现对人类出行涌现机制的可解释分析。

围绕上述研究问题，本文在出行 Agent 的认知建模与群体涌现分析之间建立统一的理论与方法框架，以实现从个体意图生成到群体行为涌现的机制分析。

1.4 研究思路与创新

1.4.1 研究思路

本文以 Agent 意图建模为核心，从个体出行意图生成与群体行为演化机制两个层面展开研究，构建兼顾行为模拟真实性与决策可解释性的研究框架。本文的总体研究思路如图 1-2 所示。本文各研究内容的研究思路如下：

首先，针对现有城市人群出行行为模拟方法普遍缺乏个体意图建模的问题，本文提出了一种基于 Agent 意图建模的城市人群移动行为模拟框架。在该框架中，通过引入人类偏好优化算法（Direct Preference Optimization, DPO），对大语言模型进行对齐训练，使模型能够学习真实个体在不同感知情境下的决策选择模式，从而刻画人类行为中的策略选择机制与偏好特征。在此基础上，本文构建了包含感知、情景记忆、认知推理与行为决策等模块的 Agent 内部结构，并显式建模 Agent-Agent 以及 Agent-环境之间的交互过程，从而形成具有认知闭环的城市人群移动行为模拟体系。

之后，针对当前人类移动行为分析方法多局限于行为统计与空间分布特征、难以解释宏观涌现现象机制的问题，本文在个体意图建模的基础上提出了一种基于出行意图的机制分析框架。该方法首先从群体 Agent 的意图序列中联合提取语义表征与结构表征，并通过意图聚类实现群体意图模式的抽象表达并进行语义归纳；在此基础上，进一步结合马尔科夫过程对离散意图状态的时序转移规律进行建模，从而为从认知层面解释复杂出行系统中的宏观涌现现象提供新的分析视角。

最后，基于上述移动行为模拟方法与意图驱动机制分析方法，本文设计并实




图 1-2 研究思路图

现了城市人群出行行为涌现机制分析系统。该系统通过调用所提出的模拟方法生成群体移动行为，并在此基础上提取群体意图结构，对宏观涌现现象进行机制分析，从而实现对城市人群移动行为涌现过程的系统化分析与验证。

1.4.2 论文主要创新点

为解决研究挑战、完成上述研究内容，本文提出了一个意图驱动的城市人群出行行为模拟与分析的统一框架，并基于东京真实出行数据集验证了模拟方法的有效性，进一步构建 O2O 外卖平台场景验证了所提出分析方法对群体涌现现象的解释能力，本文的创新之处主要体现在以下两个方面：

(1) 提出一种基于大语言模型意图推理的城市人群出行行为 Agent 建模方法。针对现有城市人群出行行为模拟方法中个体决策建模偏重行为复现、缺乏对意图与认知过程刻画的问题，本文在 Agent 决策框架中引入大语言模型驱动的认知意图模块，将个体决策过程建模为结构化的意图推理过程，并通过人类偏好优化方法学习真实个体在不同感知情境下的决策选择模式，从而实现人群 Agent 行为

模式与真实决策逻辑的对齐。该方法能够在复现轨迹结果的同时刻画个体行为背后的意图动机，从机制层面提升城市人群移动行为模拟的真实性与可解释性。

(2) 提出一种 Agent 意图驱动的群体行为机制分析方法。针对现有城市人群移动行为机制分析方法多侧重行为统计分析、难以解释宏观涌现现象形成机制的问题，本文在个体意图建模的基础上构建多层级群体分析框架。该方法通过对群体中个体意图进行聚合与聚类，提取群体层面的意图结构，并进一步对意图状态的时序演化进行建模，从而刻画群体意图结构的变化规律及其与宏观出行现象之间的关联关系。该方法突破了仅依赖轨迹空间分布或统计指标进行分析的局限，使宏观涌现现象能够被追溯至群体意图结构的演化过程，从而为复杂出行系统中的涌现行为提供可解释的机制分析方法。

1.5 研究内容与组织结构

1.5.1 研究内容

首先，针对现有城市人群移动行为模拟方法往往以对齐移动行为数据为目标、忽视个体意图认知意图对齐过程的问题，本文从 Agent 内部意图建模出发，构建了一种意图驱动的城市人群移动行为模拟方法。具体研究内容可概括为以下两部分：

(1) 提出了一种 Agent 意图建模的城市人群出行行为模拟方法。该方法基于真实历史轨迹数据，利用大语言模型构建结构化的意图推理数据，并通过人类偏好优化对模型进行对齐训练，使 Agent 在移动过程中能够生成显式的意图推理过程，从而刻画人类出行决策中的意图动机。在此基础上，构建了包含感知、情景记忆、意图推理与行为决策等模块的 Agent 内部结构，并显式建模 Agent 之间的交互过程，从而形成完整的城市人群出行行为模拟框架。最后，基于东京真实出行数据集对所提出的方法进行实验验证。实验结果表明，该方法在多项行为一致性与意图一致性指标上均表现出更高的模拟真实性与稳定性。同时，通过消融实验进一步验证了意图结构建模与偏好优化机制在整体框架中的有效性与必要性。

(2) 提出了一种基于意图演化的城市人群出行行为分析与宏观涌现机制分析方法。具体而言，首先对个体意图进行语义与结构联合表征，并通过聚类方法对连续意图特征进行抽象，得到离散的群体意图状态；在此基础上，通过马尔可夫过程对意图状态的时序演化规律进行建模，从而刻画群体层面意图结构的形成与演化过程。进一步地，将意图演化过程与出行轨迹分布变化、行为同质化以及系统效率波动等宏观现象进行关联分析，从而揭示宏观涌现现象背后的微观行为机制。为验证该分析方法在复杂现实场景中的适用性，本文进一步构建了 O2O




图 1-3 论文组织结构图

外卖平台出行场景，对骑手群体的意图演化过程与平台层面的涌现现象进行系统分析。实验结果表明，所提出的方法能够从意图层面揭示群体行为变化的内在动因，为理解复杂出行系统中的宏观涌现现象提供了一种可解释的分析框架。

(3) 实现了城市人群出行行为涌现机制分析系统。基于本文提出的意图驱动移动行为模拟方法与群体意图演化分析方法，设计并实现城市人群出行行为涌现机制分析系统，实现从个体出行意图生成、群体行为演化到宏观涌现现象分析的完整计算实验流程，为复杂出行系统的机制分析与仿真研究提供实验平台。

1.5.2 组织架构

为了能够更加清楚地阐述本研究的研究工作，本文对论文的整体组织结构进行了系统安排，如图1-3所示，全文共分为六章，各章节内容安排如下：

第一章：绪论。本章首先介绍城市人群出行行为模拟与分析这一研究课题的研究背景与现实意义，重点阐述现有出行轨迹模拟方法在个体认知建模与宏观涌

现分析方面存在的不足与挑战。随后,对国内外相关研究工作进行综述,分析现有方法在意图建模、决策解释性及群体行为机制分析方面的现状。在此基础上,概述本文的研究思路、主要研究内容与创新点,并对论文的整体结构与章节安排进行说明。

第二章:理论基础与相关方法。本章介绍本文研究所涉及的基础理论与关键方法,包括计算实验、人群出行行为模拟以及人类偏好优化与机制分析相关方法,为后续模型构建、算法设计与分析方法提供理论支撑。

第三章:基于 Agent 意图建模的城市人群移动行为模拟方法。本章提出一种基于 Agent 意图建模的城市人群移动行为模拟方法。首先介绍该方法所针对的核心问题与整体框架;随后详细阐述意图结构的建模方式以及人类偏好优化在决策学习中的具体实现;接着介绍模型的训练与执行流程;最后基于东京真实出行数据集对所提出的方法进行实验验证,并对实验结果进行分析与总结。

第四章:Agent 意图驱动的城市人群移动涌现机制分析方法。本章在前述个体意图模型的基础上,进一步从群体层面构建出行行为分析方法。首先介绍基于个体意图聚合的群体意图建模思路;随后分析群体意图的动态演化特征及其与宏观出行现象之间的关系;接着基于第三章模拟的人群出行行为场景,对群体涌现现象进行实验分析与验证;最后对实验结果进行总结,讨论所提方法在复杂出行系统分析中的适用性与优势。

第五章:城市人群出行行为涌现机制分析系统设计与实现。本章在前述方法基础上设计并实现城市人群出行行为模拟与机制分析系统。首先介绍系统总体架构与设计思路;随后阐述城市环境建模、Agent 行为模拟、意图推理与群体行为分析等核心模块的流程;最后展示系统运行界面与模拟过程,说明系统在城市人群移动行为模拟与群体机制分析中的应用效果。

第六章:总结与展望。本章对全文的研究工作与主要成果进行系统总结,归纳本文在意图驱动城市人群移动行为模拟与机制分析方面的研究结论。同时,分析当前研究的局限性,并对未来可能的研究方向进行展望,为后续相关研究提供参考。

1.6 本章小结

本章首先阐述城市人群移动行为研究的研究背景与意义。然后,结合背景内容,深入分析了当前城市人群出行行为模拟技术以及机制分析技术的研究现状。接着,针对现有研究中的不足,提出了本文的研究问题,并介绍了研究思路及论文的主要创新点。最后,总结了本文的研究内容,并概述了全文的组织结构。

第2章 理论与研究及相关方法

本章将对本文研究所涉及的理论基础和相关方法进行系统阐述。如图2-1所示，本章根据绪论中所述的研究内容，分别了主要研究内容的有关理论基础，包括涌现现象分析方法、计算实验、人类移动模拟算法、认知意图模型以及大语言模型相关研究，为本文的算法设计和理论分析提供了坚实的基础。




图 2-1 理论基础与相关方法

2.1 计算实验

计算实验方法^[37] (Computational Experiment) 是在基于 Agent 建模方法的基础上发展而来的复杂系统研究范式。与传统 Agent 建模主要关注模型构建与行为推演不同，计算实验不仅强调微观模型的设计，还系统性地引入实验方案设计、结果分析与模型验证等环节，形成完整的实验研究流程。该方法通常采用分布式思维与自底向上的建模范式，通过刻画个体 Agent 的行为及其交互机制，模拟现实世界中复杂系统的动态演化过程，从而揭示宏观规律与内在机理。

计算实验的核心目标并非仅构建一个数字化仿真系统，而是形成一个能够在

一定程度上替代真实复杂系统的虚拟实验环境，使研究者能够在其中开展可控、可重复的实验分析。相比传统仿真方法，计算实验更加重视基于个体行为的动态演化机制以及系统层面的反馈过程，并通过“反事实”推演与参数干预，分析不同条件下系统可能呈现的多种演化路径。




图 2-2 计算实验框架图

整体流程如图2-2所示,从方法论角度看,计算实验的研究框架通常可概括为一个包含五个环节的闭环反馈过程:人工社会建模、实验系统构建、计算实验设计、实验结果分析以及实验模型验证^[9] 各环节相互关联,并在反复迭代中不断修正模型与实验方案。

(1) 人工社会建模: 人工社会建模是计算实验的基础环节,其目标是围绕研究问题对现实复杂系统进行抽象,构建可计算的人工社会。该过程通常包括个体模型、环境模型与规则模型三个方面。个体模型用于刻画 Agent 的感知、决策与学习能力,以模拟现实系统中的行为主体;环境模型描述物理或社会环境在计算机中的映射形式,可根据问题规模采用实体型或网格型建模;规则模型则定义 Agent 之间以及 Agent 与环境之间的交互机制,以保证系统演化过程的合理性。

(2) 实验系统构建: 在人工社会模型的基础上,需要进一步开发实验系统以支撑大规模计算实验的运行。实验系统依托具体的仿真平台实现 Agent 的微观行为与交互逻辑,使系统在宏观层面能够涌现出整体性演化规律。该环节关注模型的可执行性与稳定性,是连接理论建模与实验分析的关键步骤。

(3) 计算实验设计: 计算实验设计旨在制定科学合理的实验方案,以提高研究效率并控制实验复杂度。研究者需要根据具体研究目标筛选关键变量,并设计相应的参数组合与实验场景。当系统影响因素较多时,变量组合往往呈指数级增

长,因此通过实验设计方法对变量进行约束与优化,对于在有限计算资源下完成有效实验尤为重要。

(4) 实验结果分析:实验结果分析通常从宏观、中观与微观三个层面展开。宏观层面关注系统整体结构与演化趋势;中观层面分析群体或子系统的行为模式;微观层面则聚焦于个体 Agent 的决策过程与行为差异。通过情景干预、对照实验与反事实推演,可以进一步揭示系统内部变量之间的动态影响关系,并加深对演化机制的理解。

(5) 实验模型验证:实验模型验证用于评估计算实验系统对现实系统演化规律的刻画能力,是保障实验结论可信度的重要环节。验证过程通常包括数据验证、过程验证与结果验证,分别用于检验实验输入数据的合理性、系统运行逻辑的正确性以及实验输出结果的有效性。

作为一种标准的交叉学科研究方法,计算实验的发展与复杂系统理论及计算机仿真技术的进步密切相关。其本质在于将“反事实”过程算法化,结合数据驱动方法、涌现机制分析与多重世界视角,为复杂系统的量化研究提供数字化与计算化手段。相较于传统实物实验,计算实验具有更高的可控性与可重复性,研究者可以通过调整环境参数或触发特定事件,在虚拟实验平台中系统性地考察不同因素对系统行为的影响。

目前,计算实验已成为复杂系统研究中的重要工具,并广泛应用于智能交通系统^[38]、生态环境系统^[39]以及政治生态系统^[40]等高风险、高成本或难以在现实中直接开展实验的领域。通过构建不同抽象层次的人工社会模型,计算实验不仅能够复现现实系统中可能出现的宏观现象,还能够用于解释这些现象背后的内在机制,为复杂系统分析与决策提供有力支持。

2.2 城市人群移动行为模拟方法

城市人群移动模拟是城市计算与智能交通领域的核心研究问题之一,其目标在于刻画个体在时空环境中的移动决策过程,并在此基础上预测或模拟群体层面的演化规律。现有城市人群移动行为模拟研究通常将个体轨迹表示为按时间排序的时空访问序列。形式化地,定义个体的一段移动轨迹为 $x = \{s_1, s_2, \dots, s_n\}$ 其中每个访问事件表示为三元组 $s_i = (t_i, l_i, e_i)$, t_i 、 l_i 与 e_i 分别表示访问时间、空间位置以及对应的活动语义标签。需要指出的是, e_i 通常来源于对轨迹结果的语义抽取或行为标注,并不直接等价于个体在决策时刻的内在认知意图。在真实移动行为数据层面,可记数据集为 $X = \{x_1, x_2, \dots, x_N\}$, 其中 N 表示样本数量。移动行为模拟的核心目标是在给定初始状态与环境约束条件下,学习生成新的轨迹集合 $Y = \{y_1, y_2, \dots, y_N\}$, 使其在时空统计特性、行为模式分布及活动语义一致性

等方面与 X 保持一致。围绕这一目标，已有研究大致可以分为三类：传统基于规则或统计的轨迹预测方法、深度学习驱动的轨迹预测方法，以及近年来兴起的基于大语言模型的智能体模拟方法。

2.2.1 知识驱动模拟方法

知识驱动的移动模拟方法强调引入领域知识、专家经验或结构化语义信息，以增强人群移动模拟的合理性与可解释性。与单纯依赖数据分布学习的统计模型不同，该类方法通过显式建模规则体系、活动结构或语义关系，对个体移动行为施加约束或提供决策依据。从发展脉络上看，相关方法可分为统计与机制假设驱动方法、规则与活动结构驱动方法，以及语义与知识图谱驱动方法三个层次。

在早期研究中，人群移动轨迹建模主要基于随机过程理论。Song 等提出一阶马尔可夫模型^[41]，将状态定义为访问的位置，并通过构建转移矩阵刻画位置之间的转移概率，从而生成轨迹序列。随后，隐马尔可夫模型（Hidden Markov Model, HMM）^[42]被用于刻画轨迹中的潜在活动状态。HMM 将轨迹分解为一系列隐状态，每个隐状态对应轨迹的一个活动片段，而观测状态为实际访问位置。模型通过学习隐状态之间的转移概率以及观测概率来生成新的轨迹序列。此外，探索与偏好返回模型（Exploration and Preferential Return, EPR）^[41]从探索与回访行为的统计分布角度刻画人类移动规律。




图 2-3 TRANSIMS 模型^[43]

随着出行行为研究的发展，研究者开始引入领域知识与专家规则构建移动生成模型。基于活动的模型（Activity-Based Model, ABM）是规则与活动结构驱动方法的典型代表。该类方法认为个体移动行为源于日常活动需求，模型通常首先生成个体的活动序列，再根据活动类型分配时间与空间位置，并结合交通网络进行路径选择。在此基础上，多 Agent 交通仿真系统 TRANSIMS 框架^[43]将合成人

口生成、活动计划、路径选择、微观交通仿真与反馈学习整合为模块化体系，实现大规模个体层面的动态交通模拟，如图2-3所示。该类方法的核心在于通过预定义规则、作息结构与城市功能分区知识，对移动行为进行结构化约束。

近年来，随着城市数据与地理信息系统的发展，研究开始引入语义信息与知识图谱对轨迹生成过程进行约束。语义轨迹模型^[44]将轨迹表示为位置、时间与活动语义的组合，通过引入POI类别与功能分区信息增强轨迹语义表达。在知识图谱驱动框架下，城市空间被表示为将城市空间建模为语义图结构。^[26]这类方法弥补了传统统计模型缺乏语义表达能力的不足，但通常仍缺少对个体内部决策机制的刻画。


2.2.2 数据驱动的模拟方法

数据驱动的轨迹生成算法旨在从大规模观测到的真实轨迹数据中学习移动模式、规律及特征，进而构建模型以生成新的合成轨迹。相比于传统方法，此类算法不依赖于人工设定的物理参数，而是侧重于通过机器学习模型捕捉数据的潜在分布。根据核心生成模型的不同，主要可分为基于变分自编码器、生成对抗网络以及强化学习的方法。

变分自编码器 (Variational Autoencoder, VAE) 因其在捕捉数据潜在分布及生成平滑潜空间方面的优势，被广泛应用于轨迹生成任务。文献^[45]提出了一种结合VAE与序列到序列 (Seq2Seq) 架构的顺序变分自动编码器 (SVAE) 模型。该模型利用多变量高斯分布来近似真实轨迹的后验分布，通过从该分布中采样并利用解码器重建轨迹。该方法有效地结合了Seq2Seq处理序列数据的能力与VAE构建连续潜空间的优势。

生成对抗网络 (Generative Adversarial Network, GAN) 通过生成器与判别器之间的对抗训练逼近真实轨迹分布，已成为轨迹生成领域的重要生成框架。早期工作如trajGANs^[10]将对抗学习机制引入移动轨迹生成，为后续研究奠定了基础。在此基础上，LSTM-TrajGAN^[11]结合循环神经网络对时序依赖进行建模，提升了轨迹序列生成的连续性；MoveSim^[46]等方法进一步增强了对长短期时序特征的刻画能力。TrajGen^[47]则尝试将对抗学习与序列建模框架相结合，实现对完整时空轨迹的联合生成。

强化学习方法将移动对象视为智能体 (Agent)，将城市环境视为环境 (Environment)，通过最大化累积奖励来学习在不同位置间的移动策略。在轨迹生成中，强化学习常与生成模型结合，如生成对抗模仿学习 (GAIL)。Choi^[12]提出的TrajGAIL模型在GAIL框架下，将车辆轨迹生成过程建模为部分可观察马尔可夫决策过程 (POMDP)。模型以当前位置作为观测变量，通过RNN嵌入估计隐状态表示，并将位置间的转移决策建模为动作，从而学习城市移动轨迹的分布特


 图 2-4 TrajGAIL 模型框架^[12]

征，如图2-4所示。

近年来，随着预训练语言模型在自然语言处理领域的成功应用，研究者开始探索其在移动行为预测中的潜力。相关工作通常将 LLM 作为序列建模工具，通过语义重编程或跨模态对齐机制，将轨迹等时空数据映射至文本空间进行建模。例如，AuxMobLCast^[16] 通过构造文本提示实现兴趣点流量预测，UrbanGPT^[18] 与 Time-LLM^[19] 等方法则通过时空编码或表示对齐提升在数据稀疏场景下的预测性能。总体而言，这类方法主要聚焦于时空模式拟合与预测能力提升，将 LLM 视为复杂序列处理与数据增强工具，而对个体移动行为背后的认知意图与决策机制缺乏显式建模。

2.2.3 意图驱动的模拟方法

随着城市人群移动研究的不断深入，学界逐渐从单纯的轨迹预测转向对移动行为背后决策逻辑与意图的刻画。意图驱动模拟强调个体内部心理状态、目标生成机制与决策推理过程在行为形成中的核心作用。

Agent 作为认知建模的基本计算载体，是具备自主决策能力的个体实体，其结构通常包括感知、决策、行为与优化等模块。形式化而言，Agent 可表示为：

$$Agent = \langle R, S_t, E_t, Y_t, V_t, N \rangle \quad (2-1)$$

其中 R 表示不随时间变化的个体属性， S_t 为动态状态， E_t 为环境事件集合， Y_t 为决策机制， V_t 为行为集合， N 为环境与任务约束。该结构为认知机制的嵌入提供了计算框架，但其本身并不规定决策的认知逻辑。

在理论层面，BDI（Belief-Desire-Intention）模型^[48]为 Agent 内部心理状态的结构化表达提供了基础。该模型将个体决策抽象为信念、愿望与意图之间的动态平衡关系，从而实现目标驱动的行为生成。同时，双系统理论^[1]指出人类决策由快速直觉系统与审慎推理系统共同构成：前者基于经验与模式匹配进行快速反应，后者则在复杂或不确定环境中进行规划与推理。




图 2-5 COPB 模型^[21]

近年来，大语言模型（Large Language Model, LLM）的快速发展为意图驱动模拟提供了新的实现路径。LLM 凭借其大规模预训练知识与上下文推理能力，能够在开放场景中生成具备语义一致性的决策链条。在推理机制层面，思维链（CoT）提示^[49]通过显式展开中间推理步骤提升了模型决策过程的可解释性，ReAct 框架^[50]进一步结合推理与行动交替机制，使模型能够在动态环境中根据反馈调整计划，相关研究还通过引入反思与多路径搜索机制增强复杂任务中的稳定性。这些方法推动 LLM 由文本生成工具转向具备规划与策略调整能力的认知 Agent。在城市移动模拟领域，基于 LLM 的认知方法主要分为两类：一类侧重于语义意图增强与显式提取，如 Mobility-LLM^[20]通过语义重编程与偏好建模提升对出行意图的刻画能力；另一类为认知生成型方法，CoPB^[21]将计划行为理论嵌入推理链条，实现意图生成与空间路径映射的分离，并构建具备记忆与反思能力的 LLM Agent^[17]以模拟群体演化过程，如图2-5所示。进一步地，Ge^[22]通过构建认知结构的同时又进行微调训练基准模型，结合数据驱动与意图驱动的一种方法。




图 2-6 涌现现象

2.3 涌现分析理论

2.3.1 复杂系统的涌现

在城市人群移动行为研究中，基于多 Agent 建模（Agent-Based Modeling, ABM）的计算实验表明，群体层面的复杂结构往往由个体间的局部交互规则自发涌现而成。基于社会力模型的多 Agent 模拟表明，当个体仅遵循期望速度与局部避让规则时，系统即可自发形成车道结构^[3]；在高密度疏散场景下，相同机制进一步诱发拱形堵塞与非线性拥堵行为^[24]。此外，在紧急疏散与恐慌传播场景中，个体竞争行为与情绪传染机制会放大局部扰动，从而诱发整体流量崩溃等反常现象^[25]。近年来，一些工作进一步引入行为异质性与社会关系结构，发现个体策略差异能够导致群体聚集、分化或竞争性结构的形成^[51]。这些研究共同表明，人群移动中的拥挤、聚集与竞争行为本质上是复杂系统中自组织过程的体现，这种由微观行为到宏观结构的跨尺度生成过程，体现了典型的涌现特征。

“涌现（Emergence）”概念最早源于复杂系统理论，是指由大量相对简单的个体构成的系统，在内部和外部元素的相互作用下，会在整体层面出现的新的属性或者模式。Jochen Fromm^[23]对涌现现象的分类为理解不同层级间的生成机制提供了结构化视角。如图2-6所示，第一种类型是简单涌现（simple emergence），涉及单向的自下而上的因果性，通常表现为基本的统计特征。相比之下，弱涌现（weak emergence）更为引人注目，因为它反映了自上而下的因果性，其中个体行为受到集体规则的影响，从而表现出集体智慧。多重涌现（multiple emergence）捕捉了不同因果层之间交互的复杂性，例如在“生命游戏”这样的模拟中，大小

和形状各异的静态和动态模式共存，展示了多层次因果关系的相互作用。最复杂的形式是强涌现（strong emergence），涵盖了微观（micro）、中观（meso）和宏观（macro）三个层次。

文献^[52,53]对涌现现象的特征进行了系统总结，指出其通常表现为微观到宏观的跨尺度生成过程，并伴随整体与个体之间的一致相关性、分布式控制机制以及宏观结构的不可还原性。在城市人群移动系统中，拥挤结构、交通流组织及群体聚集等现象均体现出这一跨尺度自组织特征，即宏观模式并非预先设定，而是在个体局部决策与相互作用过程中演化生成。因此，理解城市移动中的涌现现象，不仅需要刻画宏观统计规律，更需要揭示微观行为机制与群体结构之间的生成路径。

2.3.2 涌现分析方法

从研究方法上看，现有关于人群移动行为涌现现象的研究大致可归纳为三类路径。

在宏观层面，研究主要聚焦于社会复杂系统的整体演化结构与全局行为特征，强调对群体层面涌现现象及其长期趋势的统计刻画。在城市人群移动行为研究中，通常通过构建出行距离分布^[33]、停留时间分布、访问频率分布以及OD流网络^[34]等指标，揭示城市移动行为所呈现的重尾分布特征、跨尺度统计稳定性以及周期性结构等宏观规律。此类方法侧重于对系统结果的描述与归纳分析，能够揭示总体结构特征，但通常不涉及个体决策过程的生成机制建模，因此难以建立从微观行为到宏观结构之间的因果演化路径。

在中观层面，研究重点转向组织结构与群体交互机制，关注个体之间的互动规则如何通过组织层面的选择、扩散与协同机制放大为结构性模式^[35]。该方法强调结构化梳理与动力学刻画，包括：描述事件发生与发展的动力学过程；归纳关键要素与事件链结构；揭示不同时间情景之间的动态关联与逻辑结构。在计算实验框架下，情景可形式化表示为：

$$S = \langle Tr, Des, Actor, In, Action, Out, ES \rangle \quad (2-2)$$

其中， Tr 为触发条件， Des 为情景描述， $Actor$ 为参与主体， In 表示环境输入， $Action$ 为执行行为， Out 为行为输出结果， ES 为异常替代情景。该结构能够刻画事件的发生、演化与转化过程，并反映不确定性对系统路径选择的影响。在顺序逻辑模式下，情景的形成可视为样本空间 Ω 内经过多阶段决策与博弈后的路径分支过程 P ；而在条件逻辑模式下，情景的生成依赖必要条件或充分条件的组合。情景之间的转换概率受到环境影响因子的调节，从而形成具有选择性关联与演化特征的情景网络结构。




图 2-7 微观分析方法

在微观层面，计算实验以多 Agent 建模为核心，从个体认知、决策与学习机制出发，刻画主体在特定环境约束下的行为生成逻辑。该层分析强调个体异质性、自适应机制与局部交互规则，通常通过强化学习、进化机制或模仿学习等方式建模个体更新过程，揭示微观决策规则如何在动态博弈中积累并触发宏观涌现。在主体分析框架下，相关研究通常从个体层面解析现象形成的内在原因，主要包括“模型拟合分析”与“行为机制分析”两类路径^[36]。

首先，模型拟合分析旨在构建能够重现宏观结果的个体行为模型，以解释情景变化过程。如图2-7 (a) 所示，该方法通常通过行为数据挖掘与模型学习构建可演化的决策规则，并将其嵌入仿真环境以预测或解释宏观情景。该路径在结果重现与预测方面具有优势，但其分析基础仍是统计拟合假设，即宏观差异可由可替代的行为模型加以解释。因此，其所得行为规律未必真实对应现实决策机制，且难以清晰刻画情景变化与宏观结构之间的因果链条。

相比之下，行为机制分析更强调从因果逻辑出发解析宏观现象的生成机制。如图2-7 (b) 所示，该路径通常遵循“情景影响—行为取向—行为生成—宏观涌现”的分析逻辑：情景条件塑造个体的认知取向（如信念、愿望与意图），行为规则在主体互动中不断累积与放大，最终形成新的宏观结构。与模型拟合不同，机制分析并不以结果重合为目标，而是关注从微观规则到宏观结构的生成路径，以揭示人工社会演化的内在逻辑。

因此，在计算实验方法中，机制分析被认为是理解复杂系统演化的核心。为

进一步形式化描述宏观节点之间的因果关系，部分研究引入概率因果模型，对不同情景变量之间的因果依赖关系进行量化刻画，从而增强机制解释的严谨性与可验证性。

2.4 大语言模型相关理论

近年来，大规模预训练语言模型（Pre-trained Language Models, PLMs）在自然语言处理领域取得显著突破^[54]。基于 Transformer 架构^[55]，研究者通过在海量语料上进行自监督预训练，使模型能够学习语言的语法结构、语义关系与上下文依赖特征，并在多种下游任务中展现出良好的泛化能力。随着模型参数规模的持续扩展，大语言模型（Large Language Models, LLMs）^[56] 逐渐表现出上下文学习、指令遵循与逐步推理等能力，展现出跨任务迁移与复杂推理的潜在优势。

微调（Fine-Tuning）是指在大规模预训练语言模型（Large Language Models, LLMs）已学习到通用语言知识的基础上，利用特定下游任务数据对模型参数进行进一步优化，从而提升模型在目标任务上的性能表现。基于 Transformer 架构的预训练语言模型能够在大规模语料上学习通用语言表示，并通过 Fine-Tuning 实现对不同下游任务的快速适配。相比于从零开始训练模型，微调能够显著降低数据需求与训练成本，同时保留预训练阶段所获得的语义表示能力，因此成为当前大语言模型应用的主流范式^[54,57]。

传统的全量微调（Full Fine-Tuning）通过对模型的全部参数进行更新，使其充分适应下游任务分布。该方法具有较强的表达能力，但随着模型规模提升至数十亿甚至百亿级参数^[56]，全量微调对 GPU 显存、计算资源与训练时间提出了极高要求，在资源受限场景下难以推广。此外，大规模参数更新还可能导致训练不稳定与灾难性遗忘问题。

为降低微调成本，Houlsby 等人提出 Adapter-Tuning 方法^[58]，通过在网络中插入轻量级适配模块，仅更新少量新增参数即可完成任务适配。此类方法随后被统称为参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）。在此基础上，LoRA（Low-Rank Adaptation）^[59] 进一步提出利用低秩矩阵分解对权重更新进行建模。其核心思想是在冻结原始权重 $W^{(0)}$ 的前提下，引入两个低秩矩阵 A 与 B ，将权重增量表示为：

$$W_{\text{new}} = W^{(0)} + \Delta W = W^{(0)} + BA \quad (2-3)$$

其中矩阵秩 $r \ll d$ ，仅需训练少量新增参数即可实现任务适配。该方法在大规模模型上表现出优良的参数效率与训练稳定性，成为当前主流的高效微调技术之一。

QLoRA (Quantized LoRA)^[60] 在 LoRA 的基础上引入 4-bit NF4 量化, 并通过分页优化器 (Paged Optimizer) 解决显存峰值问题, 从而在保持模型性能的同时显著降低显存占用。因此, 相比传统全量微调方法, 基于 LoRA 和 QLoRA 的参数高效微调技术能够在保证模型性能的同时显著降低训练成本, 为大语言模型在资源受限环境下的应用提供了重要支撑。




图 2-8 RLHF 与 DPO 对齐流程对比

DPO 方法^[61] 是一种基于隐式偏好建模的偏好对齐方法。在传统的 RLHF (Reinforcement Learning from Human Feedback) 框架中, 通常需要首先利用人工偏好数据训练奖励模型, 再通过强化学习算法优化语言模型策略, 以最大化奖励模型所估计的人类偏好^[62]。如图 2-8 所示, 该流程通常包含奖励模型训练与强化学习策略优化两个阶段, 训练过程较为复杂且计算开销较高。相比之下, DPO 通过将偏好建模目标直接融入损失函数, 利用偏好数据中“偏好回复—不偏好回复”的概率差异进行优化, 无需显式构建奖励模型或进行强化学习训练, 从而简化了模型对齐流程并降低计算成本。

在 DPO 方法中, 正负样本的概率差距被表示为:

$$P_{DPO}(y_1 > y_2|x) = \sigma \left[\beta * \log \left(\frac{\pi^*(y_1|x)}{\pi_{ref}(y_1|x)} \right) - \beta * \log \left(\frac{\pi^*(y_2|x)}{\pi_{ref}(y_2|x)} \right) \right] \quad (2-4)$$

其中 x 表示输入偏好数据的 prompt, y_1, y_2 分别是偏好数据中被标注人员偏好和不被偏好的回复, π^* 是模型期望的最优概率分布, π^{ref} 是作为约束的原语言模型。

DPO 的损失函数可以被表示为:

$$L_{DPO}(\pi) = -E_{(x,y_1,y_2) \sim D} \left[\log \sigma \left(\beta * \log \left(\frac{\pi(y_1|x)}{\pi_{ref}(y_1|x)} \right) - \beta * \log \left(\frac{\pi(y_2|x)}{\pi_{ref}(y_2|x)} \right) \right) \right] \quad (2-5)$$

2.5 本章小结

本章主要概述了和本文工作相关的计算实验、城市人群移动行为模拟方法、涌现分析理论、大语言模型的基础理论知识和相关工作。

第3章 基于 Agent 意图推理模型的城市人群出行行为模拟方法

本章围绕城市人群出行行为模拟方法中个体 Agent 在出行决策过程中如何形成意图这一问题，构建了一种基于意图的 Agent 认知建模框架。该框架通过基于历史轨迹数据构建意图推理训练样本，将个体状态、环境感知信息与历史记忆作为输入，并以对应的出行意图作为监督信号，从而形成模型学习所需的训练数据。在训练阶段，首先通过监督微调（SFT）使预训练模型学习结构化的意图推理模式；随后引入直接偏好优化（DPO）进行偏好训练，使模型生成的意图推理结果能够更好地匹配真实轨迹数据，从而在给定当前状态与检索记忆的条件下生成合理的出行意图。该意图生成过程作为个体决策的核心环节，与个体属性模块、感知模块、行为模块，交互模块等模块与意图模块构成完整的基于 Agent 的人群出行行为模拟框架。最后通过广泛的实验验证了方法的优越性。

3.1 问题描述

城市人群出行行为模拟是一个高度复杂的系统。传统方法通常通过构建规则模型或统计模型来模拟城市居民或个体的出行模式与活动决策，其目标在于更好地理解、预测乃至优化城市交通系统。然而，现有传统方法缺乏对人群移动过程中生成意图的建模，难以反映真实决策过程。近年来，大语言模型在复杂语义理解、推理与角色模拟方面展现出显著优势，为模拟个体出行决策背后的认知动机提供了新的技术路径，通过将大语言模型纳入 Agent 的决策机制，使其能够在环境状态与约束条件下进行推理并生成行动决策。尽管上述方法在特定场景下取得了一定效果，但从计算实验与认知建模的角度看，多数仍以可观测的行为或轨迹结果作为主要对齐目标，而未对个体出行决策中不同认知路径的形成与切换过程进行显式建模。在训练与推理过程中，个体的意图推理过程往往处于隐式且不可区分的状态，导致模型更多是在复现行为层面的统计相关性，而非还原稳定一致的决策逻辑。为此，本章提出了基于 Agent 认知模型的城市人群出行行为模拟方法，在 Agent 决策过程中显式引入意图推理过程作为连接数据约束与认知推理的关键枢纽。

形式化地，定义个体的一段移动轨迹为按时间排序的时空访问序列 $x = \{s_1, s_2, \dots, s_n\}$ ，其中每个访问事件 $s_i = (t_i, l_i, e_i)$ 由访问时间 t_i 、空间位置 l_i 以及

对应的活动语义标签 e_i 构成。其中 e_i 表示从真实轨迹结果中可抽取或可观测的行为语义标签，通常由 POI 类型或轨迹语义信息抽取得到，用于刻画个体在该位置发生的行为类型，并可作为检验模型生成意图合理性的行为参照。给定真实移动行为数据集 $X = \{x_1, x_2, \dots, x_N\}$ ，移动行为模拟的目标是学习一个生成过程，在给定初始状态与环境约束条件下，生成新的轨迹集合 $Y = \{y_1, y_2, \dots, y_N\}$ ，使其在时空统计特性、行为模式分布以及活动语义一致性等方面与 X 保持一致。

为刻画个体出行决策中的认知动因，本章引入显式出行意图变量 I_t ，表示模型在决策时刻 t 基于状态、环境感知与历史记忆推理得到的高层行动目标，并作为连接情境感知与行为生成的中间表征，对后续移动规划施加约束，通过检验模型生成的 I_t 是否能够合理解释真实轨迹中的行为语义标签 e_i 。

3.2 基于 Agent 意图建模的城市人群移动行为模拟框架

城市人群出行行为模拟不仅需要复现个体在空间中的行为结果，还需要刻画行为背后的决策机制。然而，现有方法往往侧重于轨迹生成或行为统计规律建模，对个体决策过程中的认知结构刻画不足。为解决这一问题，本文提出一种基于 Agent 认知意图建模的城市人群移动行为模拟框架（TIMB），通过在 Agent 决策过程中显式引入意图推理机制，使模型能够在复杂情境下生成具有认知一致性的移动行为。




图 3-1 Agent 架构框架图

TIMB 框架的整体流程如图 3-1 所示。整体流程首先基于历史轨迹数据构建训练数据，包括用于初始化 Agent 的行为特征与个体属性信息，以及用于训练模

型生成结构化意图推理的训练样本。随后，通过监督微调（SFT）与直接偏好优化（DPO）对预训练模型进行对齐训练，从而获得能够生成稳定意图推理结果的模型。

在此基础上，Agent 认知意图建模框架由个体状态层、感知模块、情景记忆模块、认知意图模块与行为模块协同构成。为形式化刻画单个 Agent，本文将其表示为五元组

$$\text{Agent} = \langle S, P, M, C, A \rangle \quad (3-1)$$

其中 S 表示个体状态层，用于刻画个体的属性与异质性特征； P 为感知模块，负责获取当前所处环境状态与群体交互信息； M 为情景记忆模块，用于存储与检索历史经验； C 为认知意图模块，在经验驱动与推理驱动之间进行动态权衡，生成行为导向； A 为行为模块，负责执行具体出行与交互行为。通过 Agent 在城市模拟环境中的持续交互与决策，个体在每个时刻生成出行意图并执行相应行为，从而形成整体移动轨迹。

TIMB 框架的核心功能由三个关键部分构成：情景记忆模块、认知意图模块以及模型训练方法，同时设计了一套基于真实轨迹数据的训练数据构建流程，用于支撑模型训练过程。通过引入情景记忆与显式意图推理机制，框架能够在传统轨迹生成模型的基础上刻画个体决策过程中的推理意图结构，从而弥补仅依赖行为统计规律难以解释行为动因的不足。其中，情景记忆模块通过分层存储、生命周期管理与相似性检索机制组织历史经验，为经验驱动的意图生成提供参考；认知意图模块在个体属性约束下综合感知信息与检索记忆生成结构化推理链，并输出出行意图；模型训练模块则通过监督微调（SFT）与直接偏好优化（DPO）对预训练模型进行对齐，以提升意图推理的稳定性与一致性。下面将分别对情景记忆机制、认知意图生成过程以及模型训练与数据构建方法进行详细介绍。

3.2.1 情景记忆模块

为刻画城市人群移动过程中个体出行意图的形成与演化机制，Agent 需要具备对历史移动经验进行存储与调用的能力。基于此，本小节将个体过往的出行行为与情景信息抽象为可持续更新的情景记忆，并将其作为后续决策推理的重要输入。考虑到城市环境具有动态变化和情景依赖性，本文构建了一种情景记忆模块，通过分层存储结构与时序动态管理机制，对个体历史出行情景信息进行组织与更新，从而支撑 Agent 在复杂环境中的近似认知决策与意图推理过程。

在记忆存储模型中，本文将个体记忆组织为集合结构，每个 Agent 均维护一组独立的记忆集合，用于记录其与环境及其他 Agent 交互过程中积累的经验信息，包括环境状态、感知情景信息、决策过程及其执行结果等。形式化地，Agent

在任意时刻 t 的全局记忆库表示为 M_t 。单条记忆 $m \in M_t$ 被表示为三元组：

$$m = (p, s, I) \quad (3-2)$$

其中， s 表示历史时刻个体的状态信息， p 表示该时刻感知到的情景结构或环境观测， I 表示在该情景下生成的显式意图推理结果。

当 Agent 在时刻 t 感知到新情景 p_{new} 并完成行为后，系统生成新记忆 m_{new} 并写入记忆集合。为维护记忆的时效性，系统检索与当前情景 p_{new} 相关的历史记忆，并计算情景信息差异度量 $\Delta(p_m, p_{new})$ 。若差异超过预设阈值 ϵ ，则判定环境状态发生显著变化，系统将对对应旧记忆的生命周期截断至当前时刻：

$$t_m^{end} \leftarrow t, \quad \text{if } \Delta(p_m, p_{new}) > \epsilon. \quad (3-3)$$

其中， p_m 表示记忆 m 所对应的历史情景结构， $\Delta(p_m, p_{new})$ 为定义在统一情景表示空间中的结构差异度量，用于刻画当前情景与历史情景之间的结构差异。当该差异超过阈值 ϵ 时，认为环境已发生显著变化。该机制并非物理删除旧记忆，而是通过更新其有效时间窗口使其退出后续决策过程，从而实现基于环境演化的自适应遗忘机制。

在决策阶段，为高效检索与当前情景相关的历史经验，本文构建了一种结合情景结构匹配与时间衰减机制的记忆检索函数，用于在记忆集合 M_t 中对历史经验进行加权排序与筛选。对于当前时刻 t 的情景表示 p_t ，系统对任一历史记忆 $m \in M_t$ 计算其综合匹配得分：

$$\text{score}(m | p_t) = \text{sim}_p(p_t, p_m) \cdot \exp(-\lambda(t - t(m))), \quad m \in M_t \quad (3-4)$$

其中， p_t 表示当前决策时刻的情景表示； p_m 表示记忆 m 在生成时所对应的状态； $\text{sim}_p(\cdot, \cdot)$ 表示定义在情景表示空间中的相似度函数，本文采用余弦相似度计算当前情景表示 p_t 与历史情景表示 p_m 之间的相似度； $t(m)$ 表示记忆 m 的生成时刻； $\lambda > 0$ 为时间衰减系数，用于控制历史经验影响随时间递减的速率。

该检索函数综合考虑情景结构相似性与时间衰减机制。其中， $\text{sim}_p(p_t, p_m)$ 用于刻画当前情景与历史情景之间的结构匹配程度，使 Agent 倾向于优先调用与当前环境结构相近的历史经验；时间衰减因子 $\exp(-\lambda(t - t(m)))$ 则体现认知决策中的近因效应，使近期经验在推理过程中具有更高的激活概率。

最终，系统依据匹配得分从记忆库 M_t 中选取得分最高的 Top- K 条记忆构成候选集合：

$$\tilde{M}_t = \text{TopK}_{m \in M_t}(\text{score}(m | p_t)) \quad (3-5)$$

其中， $\text{TopK}_{m \in M_t}(\cdot)$ 表示在记忆集合 M_t 上定义的截断排序算子，即选取得分最高的前 K 条记忆。参数 K 为预设正整数，用于限制每一决策轮次中可被激活的记忆数量，从而刻画有限认知资源约束下的选择性检索机制。通过该机制，Agent

能够优先调用结构相似且时效性较强的历史经验，从而支撑后续意图推理与行为决策过程。

3.2.2 认知意图模块




图 3-2 认知意图模块

认知意图模块用于刻画 Agent 在当前状态、感知信息以及检索记忆条件下的意图生成与决策机制。如图3-2所示，从结构上看，该模块由两个相互衔接的子过程构成：首先由大语言模型生成高层认知意图，其次在该意图约束下完成行为规划与空间选择。前者负责在给定情境条件下确定意图，后者在生成的意图下完成具体实施路径的确定。通过引入这一分层结构，本文将移动决策从直接的状态到行为映射问题，转化为包含意图生成与行为规划两个阶段的认知生成过程，从而在决策层与执行层之间建立显式的推理过程。

在意图生成阶段，Agent 以当前状态 s_t 、感知信息 p_t 以及从情景记忆模块检索得到的记忆片段集合 $\tilde{M}_t$ 为输入，构建认知上下文，并通过显式推理链形成当前行动意图。整体上，意图生成过程可表示为

$$I_t = F(p_t, s_t, \tilde{M}_t), \quad (3-6)$$

其中 $F(\cdot)$ 表示由大语言模型驱动的多约束认知生成过程。 F 的内部结构采用显式思维链展开。模型围绕输入上下文逐步生成中间推理结果，通过多重认知约束形成最终移动的意图 I_t 。具体而言，意图生成过程由两个相互协同的子机制构成。模型对历史情境三元组 $(p_{t_k}, s_{t_k}, I_{t_k})$ 与当前决策语境 (s_t, p_t) 之间的结构同构性与意图逻辑可迁移性进行联合评估。当检索到的记忆在认知结构层面呈现高度

一致时，系统直接复用对应的历史意图 I_k ，实现低成本决策收敛。该经验复用机制在认知结构上与双系统决策理论中的启发式路径相一致。该理论认为，人类决策通常在经验驱动的快速判断与分析驱动的推理过程之间动态切换^[1]。相关研究表明，在出行行为等具有稳定模式的情境中，个体往往依赖习惯驱动的启发式决策，从而减少显式认知推理^[2]。

当模型判断需要启动进一步推理时，首先基于当前状态 s_t 与检索记忆 $\tilde{M}_t$ 的一致性评估历史经验的参考价值。若二者在语义或结构层面具有较高匹配度，则增强对既有经验模式的依赖；若一致性较低，则降低历史经验的权重，并更多依据当前情境信息进行推断。该动态权重调节机制使系统在熟悉情境下实现高效收敛，在陌生情境中保持必要的探索能力。

在此基础上，模型依次对候选意图施加多重约束。首先进行个体一致性校验：依据 s_t 所刻画的偏好结构、风险态度与角色定位等稳定特征，过滤与长期目标不一致的候选意图，得到个体一致性过滤后的候选意图集合 I_t^{self} 。随后进行情境可行性评估：基于当前感知信息 p_t 对候选意图的空间、资源与交互约束进行检验，得到情境可行子集

$$I_t^{\text{env}} \subseteq I_t^{\text{self}} \quad (3-7)$$

最后进行社会规范约束评估，对候选行动的社会可接受性进行检验与必要筛选。经过多重约束收缩后，系统输出唯一认知行动意图 $I_t \in I_t^{\text{env}}$ 。该分阶段压缩机制在个体层面保证决策连贯性与情境适配性，在群体层面增强模拟过程的稳定性与结构一致性。

在得到高层认知意图 I_t 后，系统需要将其映射为具体的空间行动决策。在行为规划阶段，高层认知意图 I_t 需要进一步映射为具体的空间目标位置。本文在经典引力模型框架下，引入认知意图语义约束，对传统空间交互机制进行条件化扩展。设 Agent 在时间步 t 的当前位置为 l_t ，候选位置集合记为 $L_t(I_t)$ ，表示在功能语义层面与当前认知意图 I_t 相容的位置集合。该集合通过意图语义约束筛选得到，用于限定 Agent 的空间选择范围。在此基础上，Agent 在时间 t 从当前位置 l_t 迁移至候选位置 $l_{t+1} \in L_t(I_t)$ 的概率定义为：

$$P(l_{t+1} | l_t, I_t) = \frac{\rho(l_{t+1}, I_t) d(l_t, l_{t+1})^{-\beta}}{\sum_{l \in L_t(I_t)} \rho(l, I_t) d(l_t, l)^{-\beta}} \quad (3-8)$$

其中， $\rho(l, I_t)$ 表示位置 l 的功能属性与当前认知意图 I_t 之间的语义匹配强度，用于刻画意图条件下的位置吸引程度； $d(l_t, l)$ 表示当前位置 l_t 与候选位置 l 之间的空间距离； $\beta > 0$ 为距离衰减系数，用于反映空间移动过程中的距离阻抗效应。该概率形式同时综合考虑语义匹配程度与空间距离成本，从而在经典空间引力模型基础上实现对空间吸引力的意图条件化扩展。Agent 根据上述概率分布进行采

样,得到目标位置 l_{t+1} ,从而完成从认知意图到具体空间移动行为的映射。

3.2.3 模型训练方法

在认知意图模块中,认知意图的生成由大语言模型驱动,综合利用当前环境感知信息、个体属性状态以及从记忆模块中检索到的情景记忆进行判断。在真实复杂环境中,个体根据情境复杂度进行审慎型推理决策。本节进一步关注意图推理能力的训练问题。直接依赖基础语言模型进行零样本或少样本生成,通常仅基于通用语料的统计模式进行推断,缺乏对特定 Agent 历史行为轨迹与长期决策风格的结构化建模,从而难以保证跨时段的一致性与个体特征的稳定延续。另一方面,意图本质上是一种对行为动因的解释性变量,在复杂情境下往往不存在唯一正确答案。不同推理路径可能导向相同的意图结果,仅在解释逻辑上存在差异。若采用监督微调 (SFT),模型必须拟合单一标注路径,这容易压缩合理推理空间,削弱其在新情景下的泛化能力。基于此,本文采用直接偏好优化 (Direct Preference Optimization, DPO) 对意图推理模型进行训练。该方法通过构造候选意图之间的相对偏好关系,在无需显式奖励函数或价值建模的情况下,直接约束模型在不同认知路径上的生成倾向。相较于基于绝对标签的监督学习, DPO 更符合人类在元认知层面进行意图权衡与决策选择的过程,能够有效提升模型在多情境下生成合理意图解释的稳定性与一致性。




图 3-3 人类偏好优化训练过程

如图 3-3 所示,在训练阶段,本文采用监督微调与直接偏好优化的两阶段流程,分别对 Agent 的经验预测能力与认知偏好结构进行解耦学习。

首先,通过监督微调 (SFT) 训练模型生成合理认知意图的能力。具体而言,

模型以当前状态 s_t 、感知信息 p_t 以及检索记忆 $\tilde{M}_t$ 作为输入，记为 $x_t = (s_t, p_t, \tilde{M}_t)$ 并学习条件分布 $\pi_{\text{SFT}}(I_t | x_t)$ 以生成对应的认知意图 I_t 。

在获得具备基本经验预测能力的参考模型 π_{ref} 后，进一步采用直接偏好优化对模型进行训练，使其学习在不同情境下选择合适的认知路径。DPO 的优化目标定义为：

$$\mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x_t, I_t^w, I_t^l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \left(\log \frac{\pi_{\theta}(I_t^w | x_t)}{\pi_{\theta}(I_t^l | x_t)} - \log \frac{\pi_{\text{ref}}(I_t^w | x_t)}{\pi_{\text{ref}}(I_t^l | x_t)} \right) \right) \right] \quad (3-9)$$

其中， I_t^w 与 I_t^l 分别表示在给定情境， I_t^w 为更符合人类认知偏好的优选意图， I_t^l 为相对不合理的劣选意图， π_{θ} 为待优化的意图推理模型； $\sigma(\cdot)$ 为 Sigmoid 函数； β 为偏好强度调节系数，用于控制模型在多大程度上偏离既有经验分布。

3.2.4 数据构建流程

算法 1 描述了本文基于大语言模型构建轨迹认知意图数据的整体流程。本节进一步从执行层面对该流程进行说明，重点阐明大语言模型在数据构建过程中的具体作用与功能定位。

真实轨迹数据仅记录个体的行为结果，例如访问位置及其对应的 POI 类型（餐厅、商场或办公场所），但并不包含个体在出行决策过程中形成该行为目标的认知推理过程。因此，本文利用轨迹行为中隐含的活动目标语义，结合大语言模型的推理能力，按照认知意图模块所设计的决策结构补全个体的认知推理过程，从而构建用于模型训练的结构化意图推理数据。在初始化阶段，本文提出一种基于历史轨迹的语义化个体活动画像识别方法，个体画像用于刻画长期行为偏好，从而为后续意图推理提供稳定的个体属性约束。具体而言，本文引入一组预定义的社会角色作为高层先验假设，用以刻画个体可能具备的长期行为倾向。通过将轨迹中提取的先验统计信息包括高频活动类型、时间段分布及空间聚集特征嵌入至基础提示模板中，并分别结合不同社会角色条件，调用大语言模型生成多组候选活动模式，形成候选集合 CP 。每一候选活动模式可被视为在特定角色假设下，对个体长期行为结构的语义化总结。随后，为实现从轨迹数据到活动画像的映射，本文设计了一种基于一致性评估的选择机制。具体地，对于每一候选活动模式 $cp \in CP$ ，通过构造轨迹—模式匹配提示，逐条评估其与历史轨迹中各活动实例的一致性程度，并将该一致性得分在轨迹集合上进行累积，从而获得候选模式相对于真实历史行为的整体对齐得分，从而为个体状态变量 s_t 提供稳定的行为偏好约束。最终，选择与历史轨迹集合一致性得分最高的候选活动模式作为个体的语义化活动画像。该过程等价于在给定历史轨迹观测条件下，对潜在社会角色及其对应活动模式进行后验推断与最优选择，使得 Agent 在仿真初始化阶段即具备稳定、可解释且具有行为惯性的决策基础。

Algorithm 1: 基于大语言模型的认知意图偏好数据构建

输入: 个体历史轨迹 $x^{(i)}$;
 预定义社会角色集合 $\mathcal{R}$;
 大语言模型 LLM

输出: 意图偏好数据集 $\mathcal{D}_{DPO}$

- 1 **阶段一：个体画像构建**
- 2 从 $x^{(i)}$ 提取长期活动统计特征;
- 3 **foreach** $r \in \mathcal{R}$ **do**
- 4 | 调用 LLM 生成候选活动模式 cp_r ;
- 5 **end**
- 6 选择与 $x^{(i)}$ 一致性最高的模式作为个体画像 $R^{(i)}$;
- 7 **阶段二：意图偏好构造**
- 8 **foreach** 个体 i **do**
- 9 **foreach** 决策时刻 t **do**
- 10 | 基于历史轨迹 $x^{(i)}$ 在时刻 t 之前的状态演化与环境交互，更新当前决策语境 (s_t, p_t) ;
- 11 | 从记忆库 M_t 中检索得到情景记忆 $\tilde{M}_t$;
- 12 | 调用 LLM 基于 $s_t, p_t, \tilde{M}_t$ 生成候选意图集合 $\mathcal{I}_t = \{I_t^{(1)}, \dots, I_t^{(K)}\}$;
- 13 | 从轨迹 $x^{(i)}$ 中抽取该时刻对应的行为语义标签 I_t^{ref} ;
- 14 | 将满足 $\phi(I_t^{(k)}) = \phi(I_t^{\text{ref}})$ 的候选记为 I_t^w ，其余记为 I_t^l ;
- 15 | 构造训练样本 $(s_t, p_t, \tilde{M}_t, I_t^w, I_t^l)$ 加入 $\mathcal{D}_{DPO}$;
- 16 **end**
- 17 **end**
- 18 **return** $\mathcal{D}_{DPO}$

在每一决策时刻 t ，为个体 Agent 构造用于意图推理的输入状态 x_t ，其由两部分信息组成：(1) 个体画像与历史轨迹记忆 M_t ，用于刻画其长期活动偏好与行为惯性；(2) 当前感知情景信息 p_t ，包括时间、空间位置及可达活动区域；(3) 当前个体的状态 s_t 。上述信息以结构化文本形式输入大语言模型。在给定输入状态 x_t 的条件下，大语言模型按照认知意图模块的推理结构生成一组候选高层意图：

$$\mathcal{I}_t = \{I_t^{(1)}, I_t^{(2)}, \dots, I_t^{(K)}\}, \quad (3-10)$$

其中每个候选意图均以显式语义形式表示，并对应一个可执行的活动目标。

为判断候选意图是否能够合理解释已观测的轨迹结果，本文基于显式意图

的一致性关系构造偏好判别函数：

$$R(l_t, I_t^{(k)}) = \begin{cases} 1, & \text{if } \phi(I_t^{(k)}) = \phi(l_t) \\ 0, & \text{otherwise} \end{cases} \quad (3-11)$$

其中， l_t 表示轨迹 x 中包含的在该决策阶段对应的真实目的地节点。映射函数 $\phi(\cdot)$ 的作用在于消除候选意图与轨迹结果之间语义判定的主观性，对于文本意图 $I_t^{(k)}$ ， $\phi(\cdot)$ 将其映射至预定义的功能区域类别空间（如餐饮、休闲、办公等）；对于物理位置 l_t ， $\phi(\cdot)$ 根据其对应的 POI 属性映射至同一类别空间。

基于上述判别结果，在相同输入状态 x_t 下，本文构造意图层面的偏好监督信号。具体而言，将能够满足 $R(l_t, I_t^{(k)}) = 1$ 的候选意图视为正向偏好样本，即在语义层面能够正确解释已观测轨迹行为目的的意图；而将满足 $R(l_t, I_t^{(k)}) = 0$ 的候选意图视为负向偏好样本，即与轨迹结果所体现的行为目标不一致的意图。由此，在相同输入条件 x_t 下，形成标准形式的 DPO 训练样本 (x_t, I_t^w, I_t^l) ，用于对意图生成模型进行偏好对齐训练。

3.3 模拟整体流程

在前述模型结构与训练方法的基础上，本文进一步从系统运行角度对所提出的基于 Agent 认知模型的城市人群移动行为模拟方法进行整体流程化描述。具体而言，方法可被自然地划分为两个阶段：离线训练阶段与在线执行阶段。前者侧重于从真实轨迹数据中学习人类在不同情境下的认知意图生成与路径选择偏好；后者则在仿真环境中调用已训练模型，驱动多 Agent 系统进行连续决策与轨迹生成。两阶段在功能上相互解耦、在逻辑上前后一致，共同构成完整的认知驱动人群移动模拟流程。

3.3.1 离线训练阶段

为便于总结本文方法的整体执行逻辑，算法 2 给出了基于 Agent 认知模型的人类出行模拟流程伪算法，涵盖离线训练与在线执行两个阶段。

离线训练阶段的目标在于：在仅可观测真实人类轨迹与行为结果的条件下，对 Agent 的意图生成能力与认知路径选择偏好进行数据驱动的对齐约束。为此，本文采用意图数据构建 + 偏好优化训练的两步式流程。

首先，基于历史轨迹数据与情境信息，利用大语言模型构建轨迹一意图层面的偏好监督数据。该过程不要求对真实人类意图进行显式标注，而是通过轨迹结果所隐含的高层活动目标，对候选意图进行语义一致性判别，从而在相同情境输入下构造意图层面的偏好监督信号，形成用于直接偏好优化的训练样本集。该数据构建过程已在算法 1 中给出。

Algorithm 2: 基于认知意图对齐的人类出行模拟流程**输入:** 历史轨迹数据集 X ;模拟环境 $\mathcal{E}$;**输出:** 多 Agent 移动轨迹序列 Y **1 离线训练阶段:**2 基于 X 构建个体活动画像与情景记忆初始化;3 利用大语言模型生成候选意图并构建偏好数据集 $\mathcal{D}_{\text{DPO}}$;

4 对意图生成模型进行监督微调训练;

5 基于 $\mathcal{D}_{\text{DPO}}$ 执行直接偏好优化, 得到对齐后的意图模型 π_{intent} ;**6 在线执行阶段:**7 初始化仿真环境 $\mathcal{E}$ 与 Agent 状态;8 **for** $t = 1$ **to** T **do**9 **foreach** Agent $a_i \in \mathcal{A}$ **do**

10 感知当前环境状态并检索相关记忆;

11 调用 π_{intent} 判断认知路径并生成高层意图 I_t ;12 基于 I_t 生成并执行具体移动行为 a_t^i ;

13 更新 Agent 状态与记忆库;

14 **end**15 更新环境 $\mathcal{E}$ 状态;16 **end**17 **return** Y

在获得意图偏好数据集后, 本文对意图生成模型进行两阶段离线训练。首先, 通过监督微调使模型在经验可复用情境下具备稳定复现历史行为模式的能力; 随后, 在固定参考模型的条件下, 引入直接偏好优化约束, 使模型学习在不同情境复杂度下选择经验驱动或推理驱动认知路径的生成偏好。需要强调的是, 离线训练阶段仅对意图层与认知路径选择进行对齐, 而不对具体轨迹生成策略进行任务特定强化, 从而保持模型在不同环境中的泛化潜力。

3.3.2 在线执行阶段

在线执行阶段对应多 Agent 系统在仿真环境中的实际运行过程。在该阶段, 所有模型参数保持冻结, Agent 仅通过前向推理完成从感知到行为的闭环决策。

在每一离散时间步 t , Agent 首先通过感知模块获取当前环境状态与局部交互信息, 并结合记忆模块中检索到的相关历史经验, 构造当前决策情境表示。随后, 该情境被输入至已训练完成的意图模块, 用于判断当前状态是否可由历史经

验直接解释，或是否需要触发显式的意图推理过程。

当模型判定当前情境与既有经验高度匹配时，Agent 直接生成高层行动意图并映射为具体移动行为；当模型判定经验不足以支撑决策时，则触发认知意图推理模块，在综合当前状态、个体属性与社会约束的基础上形成新的高层意图，并据此生成可执行的移动规划。生成的行为随后作用于仿真环境，驱动 Agent 状态更新，并写入新的情景记忆，为后续决策提供经验基础。

通过上述机制，Agent 在在线执行过程中实现了根据感知信息、个体状态与检索记忆进行结构化的意图推理，使群体层面的移动模式在时间演化中保持稳定性、可解释性与对环境变化的响应能力。

3.4 实验评估

3.4.1 实验设置

3.4.1.1 数据集设置

为评估本文所提出轨迹模拟与意图驱动分析方法在不同数据形态下的适用性，本研究采用两个具有代表性的东京城市范围内人群的移动数据集^[63,64]，用于模型构建与泛化能力评估。

第一个数据集包含 2019 年与 2021 年两个年度子集。2019 年子集包含 93 名用户，共生成 9880 条日级轨迹，总访问记录数为 65294 条；2021 年子集记录从 2019 年到 2021 年的完整移动数据，包含 69 名用户，共生成 6088 条日级轨迹，总访问记录数为 39023 条。轨迹数据以 10 分钟固定时间间隔进行采样，形成连续时空轨迹序列。每条记录包含用户标识、地理坐标（GPS）、时间索引及地点信息，用于刻画个体在城市空间中的连续移动过程。如表3-1所示，2019 到 2021 年期间不同类型 POI 的访问结构呈现出非对称变化趋势，其中生活保障类与开放空间类地点占比提升，而交通出行相关场所占比下降，反映出个体活动模式的阶段性重构。通过构建跨年度子集，可以用于分析社会环境变化前后的行为结构差异。

第二个数据集对应 2017 年。该数据集包含 761 名用户，访问记录数量 13839 条。数据以事件驱动方式记录用户对兴趣点（POI）的访问行为，时间间隔呈非均匀分布。每条记录包含用户标识、POI 节点、地理坐标及活动语义类别信息。相较于连续轨迹数据，该数据集在用户规模与语义维度上更为丰富，适用于评估模型在语义驱动轨迹模拟与意图推断任务中的泛化能力。

为保证不同来源数据在建模阶段的一致性，本文对原始轨迹进行统一规范化处理。首先依据观测天数与有效访问次数筛选稳定用户，并按时间顺序划分历史

表 3-1 2019 与 2021 年核心 POI 访问比例变化

POI 类型	2019 (%)	2021 (%)	相对变化率 (%)
便利店	9.23	7.29	-21.0
公共交通	5.05	3.35	-33.7
公园	3.38	4.88	+44.4
超市	2.84	3.83	+34.9
商场	3.93	4.61	+17.3
餐厅	2.54	2.53	-0.4

表 3-2 统一规范化后的轨迹数据示例

UserID	Lat	Lon	POI	移动意图	时间点
44673	35.008	139.015	Convenience Store	购物	08:00
44673	35.009	139.018	Ramen Restaurant	就餐	08:30
44673	35.004	139.060	Italian Restaurant	就餐	11:20
44673	35.009	139.085	Farmers Market	购物	14:20
44673	35.005	139.086	Soba Restaurant	就餐	18:00

轨迹与测试轨迹；随后对 POI 类别进行语义归并，将原始功能类别映射为抽象移动意图标签；同时统一空间表示形式，并将时间字段映射至 10 分钟粒度的离散时间槽。处理后，任一用户 u 的轨迹可表示为 $X^{(u)} = \{(u, p_i, \ell_i, t_i, I_i)\}_{i=1}^{N_u}$ ，如表 3-2 所示。其中 p_i 为访问的 POI， ℓ_i 为其地理坐标， t_i 为离散时间索引， I_i 为由原始类别映射得到的功能性活动标签，用于刻画该访问事件对应的移动意图。

基于三个年度的历史轨迹数据（2017、2019 与 2021 年），本文分别按照第 3.2.4 节所述流程，独立构建对应的 SFT 与 DPO 训练数据集。其中，2017 年数据构建 SFT 样本 13,462 条，DPO 偏好样本 7,628 对；2019 年数据构建 SFT 样本 9,610 条，DPO 偏好样本 5,446 对；2021 年数据构建 SFT 样本 5,922 条，DPO 偏好样本 3,356 对。各年度训练数据均仅基于对应年度的历史轨迹构造，训练与测试轨迹在时间上严格划分，以避免跨阶段信息泄漏。

3.4.1.2 实验参数设置

所有实验的轨迹模拟与模型训练均在统一的计算服务器上完成。该服务器配备 Intel Core i7-13700KF 处理器、4 张 NVIDIA GeForce RTX 4090 显卡（单卡

24GB 显存), 操作系统为 Ubuntu 22.04 LTS。多卡环境主要用于并行实验与不同数据规模设置下的对比分析。

实验中以 Qwen-3-8B 与 Lllama-3.1B-8B 两个来自不同模型家族模型作为基础语言模型, 以验证方法对不同预训练架构的适用性。除数据规模与 Agent 数量外, 其余参数均采用表 3-3 中所示的默认设置, 以保证不同实验结果之间的可比性与复现性。在 SFT 阶段, 采用参数高效微调策略 (LoRA) 对基座模型进行监督微调, 在保持基础参数冻结的前提下, 仅更新低秩适配参数。上述参数在预实验中进行过小范围调优, 在保证训练稳定性的前提下取得较优性能。为确保不同实验间的可比性, 正式实验均采用统一配置。

表 3-3 SFT 与 DPO 阶段核心训练参数配置

参数类别	SFT 阶段	DPO 阶段
基础模型	Qwen3-8B / Llama-3.1-8B	
训练精度与量化	BF16 / 4-bit NF4	
优化器	Paged AdamW (32-bit)	
学习率调度器	Cosine	
LoRA 配置	$r = 16, \alpha = 32, \text{Dropout} = 0.05$	
初始学习率	2×10^{-4}	1×10^{-5}
全局批次大小 (Batch Size)	32	32
最大序列长度	2048	2048 (Prompt: 1024)
训练轮数 (Epochs)	3	1
Warmup 比例	0.03	0.03
DPO β 系数	-	0.1

3.4.1.3 Agent 模型设置

在实验设计阶段, 2中通过设计 Agent 的角色状态、与交互行为进行初始化, 在实验中将城市人口抽象为学生 (S)、教师 (T)、办公室职员 (O)、夜班工作者 (N)、外卖员 (D) 及零售员工 (R) 六类核心主体。表 3-4 详细记录了各类主体在模拟周期内的动态状态变量及其行为耦合逻辑。

在该建模框架下, 交互机制一栏采用了符号化的表达, 旨在客观描述主体间的行为触发关系。例如, 算子 $R \rightarrow D$ 描述了零售端需求对配送行为的逻辑驱动, 而集合符号 (如 $\{S, O, N\} \rightarrow R$) 则统一记录了多源服务请求对零售节点库存 inv_i 和负荷 w_i 的时空压力映射。该映射表构成了本研究 Agent 模型的状态描述基础,

表 3-4 城市角色动态状态与交互逻辑映射表

社会角色	动态状态描述	主体交互与行为耦合记录
学生 (S)	(f_t, s_t, d_t) 疲劳, 课表, 需求	$T \rightarrow S$: 记录教学信息与知识流向 $S \rightarrow R$: 记录线下零售消费行为 $D \rightarrow S$: 记录外卖订单交付过程
教师 (T)	(w_t, s_t) 负荷, 课表	$T \rightarrow S$: 记录教学任务同步过程 $T \leftrightarrow \{O, R\}$: 记录公共服务资源共享行为 $D \rightarrow T$: 记录工作餐配送响应过程
职员 (O)	(w_t, f_t) 负荷, 疲劳	$O \rightarrow R$: 记录零售或商务服务行为 $D \rightarrow O$: 接收办公区物资配送响应记录 $O \leftrightarrow O$: 跨部门业务流协同记录
夜班者 (N)	$(f_t, shift_t)$ 疲劳, 班次	$N \leftrightarrow R$: 记录夜间生活资源补给行为 $D \rightarrow N$: 记录深夜时段物资交付过程 $N \leftrightarrow N$: 记录岗位职责的错峰衔接过程
外卖员 (D)	(o_t, i_t, f_t) 订单, 收入, 疲劳	$R \rightarrow D$: 记录零售端订单取货响应 $D \rightarrow \{S, O, N\}$: 记录终端配送交互与反馈 $D \leftrightarrow D$: 记录物流路径的逻辑衔接
零售员 (R)	(inv_t, w_t) 库存, 负荷	$\{S, O, N\} \rightarrow R$: 记录多源随机服务请求 $R \leftrightarrow D$: 记录订单交接与实时库存变动 $R \leftrightarrow R$: 记录供应链补给逻辑

确保了城市功能交互在微观层面的逻辑完整性。

3.4.1.4 对比方案介绍

在本研究中, 为了全面评估所提出的双层意图驱动 Agent 模型的性能, 我们将该算法与一系列涵盖不同技术范式的基线算法进行了对比。这些基准方法包括基于循环神经网络 (RNN) 和注意力机制 (Attention) 的经典深度学习模型、基于生成对抗思想的模仿学习方法, 以及近期出现的基于大语言模型 (LLM) 的生成式预测方法。具体而言, 选取的对比方案如下:

- **DeepMove**^[65]: 这是一种经典的基于注意力机制的循环神经网络模型, 旨在从稀疏的历史轨迹中捕捉周期性模式。该模型通过引入历史注意力模块, 能够有效提取长周期的移动规律。
- **TrajGAIL**^[12]: 这是一种基于生成对抗模仿学习 (的轨迹生成方法。该方法打破了传统似然最大化 (MLE) 的限制, 将轨迹生成建模为模仿学习过程, 通过生成器与判别器的对抗训练, 致力于学习真实人类移动数据的潜在分布策略。
- **LLMMob**^[63]: 这是一种利用大语言模型进行人类移动性预测的代表性方

法。该算法将用户的历史轨迹序列化为文本提示，利用 LLM 强大的上下文推理能力和世界知识来预测下一个位置。

- **Chain-of-Planned-Behaviour (CoPB)**^[21]: 该方法提出了一种受计划行为理论 (Theory of Planned Behaviour, TPB) 启发的 LLM 工作流程，用于少样本人类出行行为生成。CoPB 将态度 (attitude)、主观规范 (subjective norms) 与感知行为控制 (perceived behaviour control) 等认知结构嵌入到行为生成过程中，通过逐步推理用户下一步移动意图，从而提升移动意图推断和轨迹生成的准确性。
- **LLM-Driven Cognitive Modeling for Personalized Travel Generation (LDCM_PT)**^[22]: 该方法将大语言模型引入认知出行建模框架，构建包含感知 (Perception)、记忆 (Memory)、推理 (Reasoning) 与执行 (Actuation) 等模块的认知架构，以模拟个体化出行决策过程。该方法以预训练 LLM 作为通用认知底座，并基于真实公交与地铁刷卡数据对模型进行参数高效微调 (LoRA)。

3.4.1.5 实验评价指标

本研究旨在评估所提出轨迹模拟框架在个体层面上对人类出行与活动行为的刻画能力。不同于仅关注宏观流量统计的评估方式，本文从个体活动的空间模式、时间节律以及语义分布等多个维度出发，使用一组与个人活动特征密切相关的评价指标，以全面衡量生成轨迹在统计分布与行为规律上的合理性与一致性。

具体而言，本文从行为层面与认知层面两个层面展开评估。在行为层面，从空间统计特征、时间节律特征以及时空联合结构三个维度对生成轨迹进行定量分析；在认知层面，则从意图推断准确性及其类别判别稳定性两个方面评估模型的认知合理性。本文区分动态意图变量与语义类别标签两个层级。 I_t 表示个体在时刻 t 的认知意图，是随时间演化的随机变量； c 表示离散意图类别标签，属于语义空间 C ，因此有 $I_t \in C$ 。在监督评估中， I_t 的真实取值记为 c ，模型预测结果记为 $\hat{c}$ 。设测试样本集为 $S = \{(x_i, c_i)\}_{i=1}^N$ 。各指标定义如下。

(1) 步长距离 (Step Distance, SD)

步长距离用于衡量相邻决策步之间的空间移动尺度，反映轨迹的空间扩散特征。

$$d_i = \text{Dist}(l_i, l_{i+1}), \quad (3-12)$$

其中 $\text{Dist}(\cdot)$ 为地理距离函数。通过分析步长分布 $P(d)$ ，评估模型是否再现真实轨迹的重尾结构特征。

(2) 步长时间间隔 (Step Interval, SI)

步长时间间隔刻画相邻决策之间的时间跨度，用于反映行为节律结构。

$$\Delta t_i = t_{i+1} - t_i. \quad (3-13)$$

通过统计 $P(\Delta t)$ ，评估模型对长停留与高频移动阶段的刻画能力。

(3) 日常活动作息分布 (Daily Activity Routine Distribution, DARD)

该指标描述个体在不同时间片从事不同活动类别的概率分布，用于检验时间节律与语义活动之间的耦合关系。

$$P(t, c), \quad t \in T, c \in C. \quad (3-14)$$

(4) 时空访问分布 (Spatial-Temporal Visits Distribution, STVD)

时空访问分布刻画轨迹在“何时-何地”层面的联合结构，用于评估模型在细粒度时空约束下的合理性。

$$P(g, t), \quad g \in \mathcal{G}, t \in T. \quad (3-15)$$

(5) 意图准确率 (Intent Accuracy, IAcc)

意图准确率衡量模型整体意图识别的正确比例。

$$\text{IAcc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\hat{c}_i = c_i). \quad (3-16)$$

(6) 意图 F1 分数 (Intent F1-Score, IF1)

F1 分数综合刻画模型在类别判别中的精确率与召回率平衡性，在类别不均衡情况下具有更稳定的评价意义。

$$\text{IF1}(c) = 2 \cdot \frac{\text{IP}(c)\text{IR}(c)}{\text{IP}(c) + \text{IR}(c)}. \quad (3-17)$$

本文采用各类别 F1 的宏平均 (macro-average) 作为整体认知性能指标。

上述指标用于对比完整意图推断工作流与不同模块消融设置下的性能差异，从而分析关键认知推断步骤（如居住地与工作地识别）在意图标注准确性中的作用，并评价指标从空间移动特性、时间节律以及时空—语义联合分布等多个层面，对生成轨迹进行系统性评估，为后续不同模型与不同规模实验结果的对比分析提供了统一且可解释的评价标准。

3.4.1.6 实验方案

本研究基于数据集中的三个时间段（2017 年、2019 年与 2021 年），从行为层面与意图层面对所提出方法进行系统性评估。整体实验设计包含三个部分，分别对应性能对比、跨时段泛化与涌现复现分析，以及模块消融验证。

实验 1：选取 2017 年与 2019 年数据作为主要评估对象，与多种基线算法进行对比实验。数据按照 70% 训练集与 30% 测试集划分，在不同训练数据规模条件下，分别评估行为层面指标与意图层面指标的表现，以分析模型对数据规模变

化的敏感性及其泛化能力。

实验 2：实验 2 旨在评估模型在连续时间序列条件下对群体行为结构变化的刻画能力。实验选取 2019—2021 年的连续轨迹数据，并按照 70% 训练集与 30% 测试集进行划分，在统一的时间演化框架下学习个体行为模式及其对应的意图生成机制。该实验以 2019—2021 年期间 POI 访问比例的变化为分析对象，通过行为层面与意图层面的指标，检验模型是否能够在连续动态数据条件下捕捉群体活动结构的阶段性变化，并复现真实数据中不同类型 POI 访问比例的结构性偏移。

实验 3：基于实验 2 划分的测试集进一步开展模块消融实验。通过逐步移除或替换关键功能模块，对比不同结构配置下的行为层面与意图层面指标变化，以分析各组成模块对整体性能与涌现复现能力的贡献。

3.4.2 实验分析

3.4.2.1 实验 1：对比实验

本小节主要从行为层面以及意图层面两类指标方面，对比基于 Agent 意图建模的城市人群移动行为模拟方法与其他基线方法的整体性能。

表 3-5 行为层面指标对比结果

大语言模型 基线	方法	2017				2019			
		SD↓	SI↓	DARD↓	STVD↓	SD↓	SI↓	DARD↓	STVD↓
无	deepmove	0.015	0.161	0.563	0.626	0.009	0.195	0.550	0.662
	trajgail	0.196	0.050	0.579	0.603	0.166	0.059	0.534	0.474
QWEN	llmob	0.169	0.142	0.360	0.652	0.083	0.046	0.103	0.628
	COPB	0.127	0.060	0.195	0.637	0.069	0.057	0.124	0.652
	LDCM_PT	0.100	0.043	0.216	0.332	0.065	0.128	0.112	0.635
	TIMB (Ours)	0.023	0.032	0.173	0.327	0.044	0.042	0.093	0.557
LLAMA	llmob	0.200	0.152	0.520	0.635	0.076	0.070	0.147	0.675
	COPB	0.107	0.050	0.454	0.640	0.109	0.080	0.167	0.669
	LDCM_PT	0.126	0.085	0.281	0.500	0.095	0.182	0.143	0.624
	TIMB (Ours)	0.064	0.042	0.247	0.406	0.045	0.059	0.114	0.590

从行为层面的评价结果来看，表 3-5 给出了本文方法与多种基线方法在 2017 与 2019 两个数据集上的对比结果。整体来看，本文提出的 TIMB 方法在大多数指标上均取得了较优表现，表明通过显式引入 Agent 意图建模后，方法在模拟城

市人群移动行为统计结构方面具有更好的整体性能。在 Qwen 基座模型条件下, TIMB 在 2017 年数据集的 SI、DARD 与 STVD 三项指标上均取得最优结果, 并在 2019 年数据集的 SI 与 DARD 指标上保持最优表现。这表明, 在移动决策过程中引入显式的意图生成机制, 并在意图约束下进行行为规划, 能够有效提升模型对空间访问结构以及移动距离分布等行为统计特征的刻画能力。

进一步与传统轨迹生成方法进行比较可以发现, DeepMove 在 SD 指标上取得了最低值, 表明其能够较好地拟合整体位置访问频率分布。然而, 该指标仅反映访问概率的总体统计特征, 并不能刻画轨迹生成过程中的空间结构与行为模式差异。从表中可以看到, DeepMove 在 SI、DARD 与 STVD 等指标上均存在较大偏差, 说明其生成轨迹虽然能够复现位置访问比例, 但难以保持真实轨迹中的空间行为结构。相比之下, TIMB 在多个结构性指标上均取得更优表现, 说明引入认知意图建模后, 模型能够更好地捕捉移动行为背后的决策逻辑, 从而在整体统计结构上更接近真实数据。

在基于大语言模型的 Agent 方法中, TIMB 同样表现出明显优势。与 LLMOB、COPB 以及 LDCM_PT 等方法相比, TIMB 在多个指标上均取得更低的分布偏差。其原因在于, 现有方法大多直接利用大语言模型进行决策生成, 而缺乏对决策过程的显式结构化建模, 导致生成行为在长期模拟过程中容易产生统计偏移。本文方法通过构建结构化意图推理过程, 使 Agent 在生成行为之前首先形成稳定的移动意图, 从而在行为生成层面形成更一致的决策模式。

此外, 在不同大语言模型架构条件下, TIMB 方法仍然保持了较为稳定的性能优势。在 LLAMA 基座模型条件下, TIMB 在多个指标上仍优于其他 Agent 方法, 尤其在 2017 年数据集的 SD 与 SI 指标上取得较好结果。这表明本文提出的意图建模框架并不依赖于特定的大语言模型架构, 而能够在不同模型条件下保持稳定的行为生成能力, 体现出一定的跨架构适用性。

综上所述, 实验结果表明, 通过在 Agent 决策过程中引入显式的意图建模机制, 可以有效提升城市人群移动行为模拟在空间访问结构、移动距离分布以及整体轨迹模式等多个层面的统计一致性, 从而为后续群体行为涌现现象的机制分析提供更加可靠的行为基础。

图 4-12 给出了各模型在意图层面指标上的对比结果。需要指出的是, 本节所分析的意图来源于 Agent 在决策过程中由大语言模型生成的语言化意图描述, 因此该指标反映的是模型在语义层面对个体决策动机的表达能力。图中展示了不同方法在 2017 年与 2019 年数据集上的意图准确率对比结果。总体来看, 在两种大语言模型基座下, 各方法的意图生成准确率呈现出较为一致的变化趋势, 其中 TIMB 方法在所有实验设置中均取得了最高结果。

在 2017 年数据集上, 基于 Qwen-3-8B 的 TIMB 方法取得 82.4% 的意图准确




图 3-4 意图层面指标对比结果

率，显著高于 LLMOB (62.1%)、COPB (68.0%) 以及 LDCM_PT (74.1%)。在 Llama-3.1-8B-Instruct 模型条件下，TIMB 同样取得最高准确率 (72.2%)，相较于其他方法仍保持稳定优势。该结果表明，通过在 Agent 决策过程中引入显式的意图建模机制，能够提升大语言模型生成意图描述与真实决策意图之间的一致性；在 2019 年数据集上，各方法整体表现与 2017 年保持相似趋势。TIMB 在 Qwen-3-8B 模型条件下取得 78.3% 的意图准确率，高于 LLMOB (61.1%)、COPB (73.9%) 和 LDCM_PT (75.0%)。在 Llama-3.1-8B-Instruct 条件下，TIMB 依然取得最高准确率 (70.4%)，说明该方法在不同年份数据条件下均具有较好的稳定性；进一步比较不同模型基座可以发现，在所有方法中 Qwen-3-8B 的意图准确率整体高于 Llama-3.1-8B-Instruct，表明不同大语言模型在复杂决策语义表达能力上存在一定差异。然而，无论采用哪种模型基座，TIMB 方法均保持领先表现，说明本文提出的意图建模框架具有良好的跨模型适用性。

综合行为层面和认知层面的实验结果，尽管部分传统模型在行为层个别统计指标上具有局部优势，但在意图层面判别能力方面仍存在明显差距。这进一步说明，单纯依赖轨迹转移模式难以充分刻画高层语义意图，而通过 DPO 强化认知意图推理一致性的训练方式，能够有效提升模型对行为动机层语义结构的建模能力。

3.4.2.2 实验 2：群体移动行为分布变化的模拟能力评估

为进一步验证模型在长时间模拟场景下对群体空间结构演化的刻画能力，本文选取 2019–2021 年连续模拟过程作为实验对象。该阶段个体移动行为在长期演化过程中逐渐出现空间聚集迁移现象，城市访问热点在不同时间位置发生明显

调整。

表 3-6 2021 年行为层面指标对比结果

大语言模型基线	方法	SD↓	SI↓	DARD↓	STVD↓
无	Deepmove	0.012	0.179	0.505	0.662
	Trajgail	0.138	0.094	0.362	0.612
QWEN	llmob	0.174	0.078	0.345	0.687
	COPB	0.161	0.080	0.456	0.660
	LDCM_PT	0.081	0.064	0.344	0.608
	TIMB (Ours)	0.034	0.046	0.156	0.296
LLAMA	llmob	0.107	0.095	0.528	0.649
	COPB	0.126	0.087	0.225	0.665
	LDCM_PT	0.180	0.086	0.395	0.532
	TIMB (Ours)	0.046	0.066	0.347	0.413

表 3-6 给出了 2021 年行为层面指标的对比结果。可以看到，TIMB 在 SI、DARD 与 STVD 三项指标上均取得最优表现，说明其在空间结构一致性、出行距离分布以及整体时空访问模式方面均能够更好地拟合真实轨迹。相比之下，LDCM_PT 与 LLMOB 等方法在 STVD 与 DARD 指标上偏差较大，反映出其在长期模拟过程中难以保持稳定的空间结构分布。综合来看，实验结果表明，TIMB 在长期演化场景下能够更好地适应空间访问结构的动态变化，从而更加准确地复现城市人群移动行为的宏观空间分布特征。

表 3-6 给出了 2021 年行为层面指标对比结果。首先，与传统轨迹生成方法相比，TIMB 在 SI、DARD 与 STVD 三项指标上均取得明显更优结果，说明其在空间结构一致性与整体时空访问模式刻画方面具有更好的表现。虽然 DeepMove 在 SD 指标上取得最低值表明其能够较好拟合位置访问频率分布，但该指标仅反映访问概率一致性，而在 SI、DARD 与 STVD 等结构性指标上仍存在较大偏差，说明其生成轨迹难以保持真实移动行为中的空间结构与出行模式。

其次，在基于大语言模型的 Agent 方法中，TIMB 同样表现出稳定优势。在 Qwen 基座模型下，TIMB 在 SI、DARD 与 STVD 三项指标上均取得最优结果。在 LLAMA 基座模型条件下，TIMB 仍在多数指标上优于其他 Agent 方法，说明该方法在不同模型架构下均能够保持稳定的行为分布刻画能力。综合来看，通过在 Agent 决策过程中引入显式意图建模机制，TIMB 能够在空间访问结构、出行距离分布以及整体时空访问模式等多个层面提升模拟轨迹与真实数据之间的一致性。

进一步从意图层面对不同方法进行分析，图 3-5 展示了 2021 年各方法的意图准确率对比结果。可以看到，在两种大语言模型基座下，TIMB 均取得最高意




图 3-5 2021 年数据集意图层面指标对比结果

图准确率，其中在 Qwen-3-8B 条件下达到 77.3%，在 Llama-3.1-8B-Instruct 条件下达到 66.7%。相比之下，LLMOB、COPB 与 LDCM_PT 的意图准确率整体较低，说明其在决策语义表达方面仍存在一定偏差。这一结果表明，通过显式建模 Agent 的意图生成过程，TIMB 能够更准确地刻画个体决策动机，从而在语义层面提升移动行为模拟的合理性。




图 3-6 2019 年与 2021 年典型时段（前、中、后期）时空访问密度热力图对比

图 3-6 展示了 Ground Truth、LDCM_PT 与 TIMB 模型在对应日期的空间访问密度热力图。通过对热力图结果的可视化分析，从宏观时空尺度评估不同模型




图 3-7 角色聚集度变化结果

对人类出行行为整体分布特征及其演化趋势的刻画能力。

在 2019 年的常态化出行场景中，Ground Truth 显示出较为稳定的城市空间访问结构，主要访问热点持续集中在大型交通枢纽与中央商务区附近。TIMB 在三个代表时间点均能够较好地模拟这一空间格局，其热力覆盖范围与强度分布在整体形态上与真实轨迹保持较高一致性。相比之下，LDCM_PT 虽能够识别部分高频访问区域，但在空间连通性及边缘区域覆盖方面存在不足，表现为局部热力分布碎片化及空间连续性较差的现象。

与 2019 年相比，2021 年的 Ground Truth 在不同时间点之间呈现出一定程度的空间结构变化，中心区域的热力强度与分布形态在初期、中期与末期之间存在差异，反映出群体移动模式在年度内部的动态调整。

在该场景下，LDCM_PT 在三个时间点未能准确刻画真实的中心区域分布，其预测的高密度区域在空间位置与形态上均与 Ground Truth 存在偏差，表现出中心区域识别不稳定的问题。相比之下，TIMB 在 2021 年初期阶段能够较好定位主要活动中心，但其热力分布相对离散，空间聚集性仍有不足。随着时间推进，在中后期阶段 TIMB 对中心区域结构的刻画逐渐接近真实轨迹，在末期阶段，其空间热力分布在集中程度与整体形态上均与 Ground Truth 更为一致。

综合跨年度与时间对比结果可以发现，在具有时间变化特征的环境条件下，不同模型在空间分布刻画能力上存在明显差异。LDCM_PT 难以适应空间结构变化，而 TIMB 在整体空间结构识别方面表现出更好的稳定性与一致性，能够更准确地复现城市人群移动行为的空间分布模式。这说明在移动决策过程中引入显式意图建模，能够在微观决策层面形成更加稳定的空间选择模式，从而提升宏观空间分布模拟的真实性。

从图 3-6 可以观察到，在 2021 年末期城市空间访问热点不再集中于单一核心区域，而呈现出一定程度的空间扩散趋势。为了进一步刻画这一空间结构变化，本文引入空间集中度指标 Herfindahl–Hirschman Index (HHI)，并对不同角色在 2021 年末期相对于 2019 年的空间集中度变化进行分析，结果如图 3-7 所示。

从角色层面来看（图 3-7(a)），不同群体的空间集中度变化存在明显差异。其中，骑手群体的空间集中度显著提升，平均增加约 +2.07pp，而教师与学生等常规通勤角色的变化幅度较小，职员、夜班者与零售员等角色甚至出现一定程度下降。这一结果表明，2021 年末期城市空间结构变化并非由整体人群行为变化所驱动，而主要来源于骑手群体空间分布的显著调整；进一步从个体层面分析骑手群体的空间集中度变化（图 3-7(b)），可以发现大部分骑手的 HHI 均出现不同程度上升，其中部分骑手的集中度提升超过 3pp，个别骑手达到 +5.36pp。该现象表明，在长期演化过程中，骑手个体逐渐向少数高收益区域集中，从而在群体层面形成明显的空间聚集现象。这一结果与图 3-6 中观察到的空间热点扩散与结构调整现象相一致，为第四章骑手聚集行为形成机制的分析提供了依据。

3.4.2.3 实验 3：消融实验




图 3-8 消融实验意图层面结果

为了分析 TIMB 框架中各训练模块对不同任务阶段的作用，本文设计消融实验进行验证。考虑到前两节实验分别关注意图生成能力与长期模拟中的空间涌现现象，本节分别选取对应实验中的代表性评估场景进行分析：在意图层面，沿用实验 1 中的 2017 年与 2019 年数据集评估模型的意图生成能力；在行为层面，则选取实验 2 中 2021 年模拟末期的空间分布结果，用于评估模型在长期演化场景下的时空一致性表现。本文提出的 TIMB 模拟框架包含两个关键训练步骤：首先，通过 QLoRA 方法对预训练模型进行监督微调（SFT），使模型能够学习结构

化的意图推理模式；其次，引入直接偏好优化（DPO）机制，进一步强化模型生成意图与标注意图之间的对齐程度。鉴于上述两项步骤均围绕意图对齐进行设计，本文通过消融实验分析其对模型性能的贡献。实验基于 2017 年与 2019 年的数据集开展。其中，TIMB w/o DPO 用于评估偏好优化带来的性能增益，而 TIMB w/o SFT & DPO 则表示移除两项训练步骤后的基础模型，用于考察在缺乏意图对齐机制时的模型表现。

如图 3-8 所示，在两个数据集及两种大语言模型基座下，完整 TIMB 模型均取得最高准确率，表明 SFT 与 DPO 两个训练步骤均对意图对齐具有积极作用。当移除 DPO（TIMB w/o DPO）时，模型性能出现明显下降。以 Qwen-3-8B 为例，2017 年意图准确率由 82.4% 降至 75.1%，2019 年由 78.3% 降至 72.7%。在 Llama-3.1-8B-Instruct 模型条件下，该趋势同样存在，说明偏好优化在提升模型生成意图与真实决策动机之间的一致性方面发挥了关键作用。进一步移除 SFT 与 DPO（TIMB w/o SFT & DPO）后，模型性能进一步下降，但下降幅度相对有限。这一结果表明，监督微调能够为模型提供基础的意图推理能力，而 DPO 在此基础上进一步强化了意图对齐效果。综合来看，SFT 与 DPO 在 TIMB 框架中形成互补作用，共同提升了模型在意图生成任务中的表现。




图 3-9 消融实验时空访问热力图对比

为进一步分析各核心模块在轨迹模拟过程中对时空一致性的贡献，本文选取 2021 年模拟末期时刻，对不同消融设置生成的空间访问密度分布进行对比分析，结果如图 3-9 所示。通过将各模型生成的热力图与真实轨迹（Ground Truth, GT）进行可视化对比，从空间结构一致性与分布稳定性两个方面评估各模块的作用。

从图中可以观察到，完整 TIMB 模型生成的空间热力分布在整体结构上与 GT 最为接近，主要访问热点的空间位置与强度分布均能够得到较好复现。当移除 DPO 机制（TIMB w/o DPO）时，模型仍能够识别部分核心热点区域，但整体热力分布出现明显收缩，部分边缘活动区域未被有效刻画，说明偏好优化在提升空间分布完整性方面发挥了重要作用。进一步移除 SFT 与 DPO（TIMB w/o SFT & DPO）后，模型生成的空间热力分布呈现出明显碎片化特征，热点区域分布离散且空间结构不稳定，与真实轨迹之间存在较大偏差。相比之下，完整 TIMB 模

型在中心区域及周边活动带均形成较为连续的空间热点结构，表明 SFT 与 DPO 两个训练步骤在提升模型空间行为一致性方面具有协同作用。

3.5 本章小结

本章系统构建并阐述了一个基于 Agent 认知模型的城市人群移动行为模拟框架。从整体结构上，模型以个体属性表征、环境感知建模与情景记忆机制为基础，构建了以认知意图为核心的分层决策体系。在模拟运行层面，详细刻画了 Agent 从情境评估、意图推理到行为执行的完整决策链路，并分析了在不同环境不确定性与任务复杂度条件下认知意图的生成机制与协同调节方式。通过多组模拟与对比实验验证，结果表明，该框架在保持轨迹统计分布一致性的同时，能够更细粒度地刻画个体出行决策中的认知异质性与策略差异性，从而为后续群体行为结构分析与异常涌现机制研究提供了可解释的建模基础。

第4章 Agent 意图推理驱动的人群出行行为涌现机制分析方法

在第三章构建的微观认知意图模型基础上,本章提出一种面向城市人群移动行为的跨尺度涌现机制分析方法,旨在系统刻画个体意图、群体行为与宏观现象之间的关联。该方法针对现有研究中微观决策与宏观涌现联系不清、机制难以追溯的问题,构建了一套基于认知意图的机制分析框架,使得涌现现象能够从个体意图的生成与演化逐步映射至群体行为模式及宏观表现。具体而言,框架以城市人群移动模拟框架作为分析对象,首先从个体 Agent 提取认知意图的推理过程,并将意图进行谱式表征以便后续分析。随后,在群体层面对意图进行聚类分析,识别不同意图类别的分布与模式。最后,通过马尔科夫建模对意图的时序演化进行分析,以揭示个体意图在群体交互中的累积效应及其形成的集体行为模式,进而解释宏观涌现现象的生成机制。通过上述分层建模与分析机制,本文能够显式揭示个体认知如何在群体尺度上累积、放大并最终表现为宏观异常现象,从而为群体涌现现象的成因分析提供可解释的机制分析。在此基础上,本章通过实验对其在人类移动行为涌现分析中的有效性与适用性进行了验证,最后对本章工作进行了总结。

4.1 问题描述

本研究聚焦于城市人群移动行为中宏观涌现现象的成因分析方法。城市人群移动行为作为典型的复杂社会系统,在模拟过程中,Agent 内部状态的变化、Agent 之间以及 Agent 与环境的交互,往往会在系统层面涌现出交通拥堵、O2O 平台恶性竞争等宏观现象。传统研究通常认为,只要 Agent 的微观行为规则具备一定的现实合理性,且模拟生成的轨迹集合 Y 能够复现真实世界数据集 X 中观测到的宏观时空分布与行为特征,模型即可被视为具有现实解释性。

然而,这一基于结果对齐的判断标准存在明显局限:在复杂的群体涌现现象中,宏观轨迹结果背后的演化过程难以被清晰剖析。尤其在存在多种 Agent 模型均可生成类似宏观轨迹 Y 的情形下,机制分析的核心任务即是深入辨别:究竟哪一种微观机制才是系统涌现背后的真正因果来源。机制分析方法强调对个体 Agent 内部认知结构与决策机制的刻画,试图从微观认知结构出发,解释其如何通过交互行为逐步演化为系统层面的状态跃迁。现有研究大多仅增强了行为层面的表达能力,并未将生成行为前的潜在认知意图 I_i 作为核心分析对象,因此难

以解释个体的意图状态如何沿时间序列演化，更无法揭示这些认知模态如何在群体层面发生相互作用并最终导致宏观涌现。

为构建更加完整且具有因果追溯能力的机制分析框架，本章提出一种基于意图驱动的涌现机制分析方法。该方法首先打破了仅关注外显行为的传统范式，从个体 Agent 在决策过程中的内部意图变量 $I_t^{(i)}$ 出发，构建高保真的意图特征提取与表征模块；随后，在群体层面对海量个体意图进行离散化抽象与聚类分析，并利用马尔可夫动力学模型刻画其时序演化规律，从而揭示意图在群体交互中的累积效应及转移模式。最终，该方法通过建立潜在意图状态与实际物理行为的条件映射，在微观认知与宏观现象之间形成严密的闭环，为解析各类复杂的群体涌现现象提供了具有高度可解释性的分析工具。

4.2 基于意图模型的群体 Agent 机制分析方法框架




图 4-1 基于潜在意图状态的群体 Agent 机制分析总体框架

本节详细介绍意图驱动的群体 Agent 机制分析总体框架，重点探讨其在分析过程中如何权衡个体 Agent 的意图与群体涌现行为之间的关系，并通过行为与意

图之间相关性计算相关性分析行为和意图关系。在第四章中实现的意图驱动的 Agent 移动行为模拟，提高了模拟的真实性同时实现了 Agent 更接近人类行为。然而，计算实验通过人类移动模拟进行实验分析过程中，基于行为的分析往往过于宏观，缺少 Agent 个体行为背后的认知意图，限制了涌现现象的原因分析。为了解决这一问题，本文提出一种意图驱动的群体 Agent 机制分析方法。该方法首先跟踪模拟过程中每个 Agent 的意图变化；随后，通过分析意图演化识别新意图的产生；接着，对涌现的新意图进行聚类，构建思维时序演化图；最终，实现从微观个体行为意图到宏观异常涌现现象的机制分析。

总体框架如图4-1所示，该框架摒弃了传统的黑盒式意图判断，转而采用可解释的数学结构来刻画群体 Agent 的演化过程，为理解复杂涌现现象提供了新的分析范式。该框架主要包含四个核心阶段：首先是个体意图提取，结合第三章中模拟的基于经验与深度推理的意图推理链，按照时序分析统计并进行谱潜在表征提取；随后进行全局状态聚类，将离散的个体意图向量映射为涌现的潜在宏观意图状态；之后通过宏观的意图涌现分析，构建马尔可夫转移矩阵以量化意图间的流动概率，从而精准识别导致系统涌现的关键意图路径以及群体的行为和意图的相关性；最终，结合意图涌现的时序演化结果与群体行为之间的关联结构分析，对系统层面的涌现现象进行综合刻画与机制解释。

4.2.1 群体意图提取

理解城市群体 Agent 移动行为涌现机制，不能仅依赖外显行动结果，还需刻画行为背后的意图动机。在动态环境中，Agent 的目标选择受到环境状态、约束条件与偏好权衡的共同影响，并以结构化文本形式表达于每一时间步。为支持后续的状态抽象与时序建模，有必要将这些自然语言意图转化为可计算的数值表示。考虑到单一语义向量可能难以充分区分不同意图模式，本文在语义表示基础上引入特征维度间的统计信息作为补充，以增强表示的区分能力与稳定性，构建统一的意图嵌入向量，从而形成可用于聚类与演化分析的意图嵌入轨迹，如图4-2所示。具体而言，Agent 在完整模拟周期 T 内的意图序列表示为：

$$\mathcal{T}^{(i)} = (I_1^{(i)}, I_2^{(i)}, \dots, I_T^{(i)}), \quad (4-1)$$

其中 $I_t^{(i)}$ 为时间步 t 的结构化意图文本描述，包含环境摘要、候选目标、约束与偏好因素以及候选动作集合等字段。 $I_t^{(i)}$ 表示 Agent 在城市人群移动模拟过程中，针对当前环境状态所生成的意图推理文本。该文本记录了决策形成时所考虑的环境信息、约束条件与候选动作等要素。

对时间步 t 的意图文本 $I_t^{(i)}$ ，利用预训练语言模型编码得到 token 级嵌入矩阵




图 4-2 个体意图提取流程图

$X_t^{(i)} \in \mathbb{R}^{n_t \times d}$, 其中 n_t 为 token 数量, d 为嵌入维度。为在语义向量之外补充特征维度间的统计信息, 并缓解文本长度差异带来的尺度偏移, 构造长度归一化的局部格拉姆矩阵:

$$\tilde{G}_t^{(i)} = \frac{1}{n_t} (X_t^{(i)})^\top X_t^{(i)} \in \mathbb{R}^{d \times d} \quad (4-2)$$

该矩阵刻画特征维度之间的二阶统计关系, 其构造方式对 token 顺序不敏感; 归一化项 $\frac{1}{n_t}$ 在一定程度上缓解不同文本长度带来的尺度偏移, 在实际实现中, 设语言模型的隐藏维度为 d , 则每个时间步需计算一个 $d \times d$ 的局部格拉姆矩阵, 其时间复杂度为 $O(n_t d^2)$ 。相比仅使用 CLS 或均值向量, 该统计表示能够在一定程度上增强不同意图之间的区分能力。

考虑意图表征的时间连续性与路径依赖性, 本文采用指数移动平均 (EMA) 对局部格拉姆矩阵进行递归累积:

$$G_t^{(i)} = \gamma G_{t-1}^{(i)} + (1 - \gamma) \tilde{G}_t^{(i)}, \quad G_0^{(i)} = \mathbf{0}, \quad (4-3)$$

其中 $\gamma \in (0, 1)$ 为平滑因子。该递归形式用于平滑局部统计特征, 提升表示的稳定性。

随后对累积矩阵 $G_t^{(i)}$ 进行特征分解。由于 $G_t^{(i)}$ 为对称半正定矩阵, 其特征值均为非负实数。记按降序排列的前 $k_{\text{eig}} \leq d$ 个特征值为 $\{\lambda_j^{(i,t)}\}_{j=1}^{k_{\text{eig}}}$ 。为获得跨时间步

可比的相对谱形状，对其进行 L_1 归一化，得到谱占比向量：

$$\tilde{\Lambda}_t^{(i)} = \left[\frac{\lambda_1^{(i,t)}}{\sum_{j=1}^{k_{\text{eig}}} \lambda_j^{(i,t)} + \epsilon}, \dots, \frac{\lambda_{k_{\text{eig}}}^{(i,t)}}{\sum_{j=1}^{k_{\text{eig}}} \lambda_j^{(i,t)} + \epsilon} \right] \quad (4-4)$$

其中 ϵ 为数值稳定项。该向量用于刻画特征维度间统计信息的相对分布情况，以增强不同意图表示之间的可比性。

仅依赖谱占比会丢失嵌入空间中的具体语义方向信息，因此需要补充一阶统计特征以保留整体语义内容。为此，首先对 token 表示进行平均池化，得到该时间步的全局语义中心 $h_t^{(i)} = \frac{1}{n_t} \sum_{j=1}^{n_t} X_{t,j}^{(i)}$ 。鉴于原始嵌入维度 d 较高，为降低表示维度并提升后续计算稳定性与可比性，本文在所有时间步的语义中心向量集合上离线拟合主成分分析（PCA）投影矩阵，并保持其参数固定。随后对每个时间步的语义中心进行线性映射，得到低维语义表示 $h_{t,\text{sem}}^{(i)}$ 。所得 PCA 投影矩阵在整个实验过程中保持不变，仅作为表示空间压缩的线性映射算子，不构成模型训练或推理流程的一部分。

最终，将语义低维向量与谱占比向量进行级联，构造时间步 t 的联合嵌入表示：

$$E_t^{(i)} = [h_{t,\text{sem}}^{(i)} \parallel \tilde{\Lambda}_t^{(i)}] \in \mathbb{R}^{d_{\text{sem}} + k_{\text{eig}}} \quad (4-5)$$

其中 $h_{t,\text{sem}}^{(i)} \in \mathbb{R}^{d_{\text{sem}}}$ 为语义低维表示， $\tilde{\Lambda}_t^{(i)} \in \mathbb{R}^{k_{\text{eig}}}$ 为谱占比向量。该联合向量在压缩高维语言表示的同时，结合语义信息与统计特征，形成统一的意图表示。通过对每一时间步的意图文本重复上述表示过程，可得到完整的嵌入序列 $\{E_t^{(i)}\}_{t=1}^T$ 。

4.2.2 意图聚类抽象

为了建立微观意图特征与宏观群体演化之间的分析桥梁，本节提出一种基于聚类的潜在状态抽象与语义解析方法。本节的核心工作是：首先通过聚类算法，将复杂的连续意图特征划分为有限的离散潜在认知状态，以捕捉群体 Agent 中反复出现的稳定意图模式；随后，引入大语言模型对每个聚类簇进行联合分析，提取其对应可读的语义原型。这一从连续空间到离散语义状态的映射，旨在为宏观涌现现象提供具有高度可解释性的微观认知基础。

如图4-3所示，本节在群体与时间的联合尺度上，对所有 Agent 在整个模拟周期内生成的谱嵌入向量进行统一建模。

实现上述聚类抽象与语义解析的前期基础工作，需要将上一节所得的个体微观特征在宏观尺度上进行全局整合。通过上一节的联合特征表征，Agent 在每一时间步的意图已被映射为统一维度的连续特征向量 $E_t^{(i)}$ ，该表示刻画了单一时刻下意图内容的语义方向与认知复杂度，直接在连续特征空间中进行群体层面的演化建模对局部扰动极为敏感，且难以反映认知模式的长期稳定结构。因此，本文




图 4-3 意图聚类抽象流程

首先将分散在全部 Agent 与整个仿真周期内的连续向量 $E_t^{(i)}$ 聚合为一个全局特征集合。该集合作为标准化的数据底座，使得后续的离散化聚类能够将个体的认知演化转化为有限状态空间中的跃迁序列，从而为时序动力学建模提供统一表示。设系统中全部意图谱特征的集合为：

$$\mathcal{E} = \bigcup_i \bigcup_{t=1}^T E_t^{(i)}, \quad (4-6)$$

其中 $E_t^{(i)}$ 表示 Agent A_i 在时间步 t 的谱嵌入向量。

在构建全局特征集合 $\mathcal{E}$ 后，本节采用 K-Means 算法对其进行无监督聚类，将连续的联合特征空间划分为 k_{clu} 个离散区域。考虑到联合嵌入向量由语义低维表示与谱占比特征拼接而成，不同子特征在尺度与方差结构上可能存在差异，若直接在原始空间中计算欧氏距离，可能导致聚类结果偏向方差较大的子空间。因此，在聚类前对所有联合特征进行标准化处理，使各维度具有可比尺度，从而缓解不同子特征尺度差异对欧氏距离的影响。在此基础上，K-Means 通过最小化样本到所属聚类中心的欧氏距离平方和，得到一组聚类中心 $\{\mu_j\}_{j=1}^{k_{clu}}$ 。这些聚类中心可视为各簇样本的代表性原型，用于概括该簇中联合特征的典型形态；相应地，每一簇对应一种在数据中稳定出现的意图表征模式。在实际操作中，超参数 k_{clu} 的选取综合考虑模型可解释性、聚类稳定性与样本规模等因素，以在状态抽象粒度与统计充分性之间取得平衡。

对于任意 Agent A_i 在时间步 t 的意图谱特征 $E_t^{(i)}$ ，其对应的潜在状态标签定义为：

$$s_t^{(i)} = \arg \min_{j \in \{1, \dots, k_{clu}\}} \|E_t^{(i)} - \mu_j\|^2 \quad (4-7)$$

由此，Agent A_i 在整个模拟周期内的意图演化过程可表示为一条离散意图序

列：

$$S^{(i)} = (s_1^{(i)}, s_2^{(i)}, \dots, s_T^{(i)}), \quad (4-8)$$

其中 $s_t^{(i)} \in \{1, \dots, k_{clu}\}$ 。该离散化表示在显著压缩原始语言意图数据规模的同时，保留了意图结构随时间演化的主要模式，并为后续群体层面的状态转移建模提供了标准化的状态基础。

连续谱嵌入 $E_t^{(i)}$ 已被映射为离散潜在认知状态 $s_t^{(i)} \in \{1, \dots, k_{clu}\}$ ，其中每一状态 j 由其对应的聚类中心 μ_j 表征。尽管该离散化表示在统计建模层面具备良好稳定性，但意图标签本身仍缺乏直接的语义可解释性。为此，本文进一步回溯联合特征空间与原始意图文本之间的对应关系，为每一个潜在意图状态构建可读的语义原型。具体而言，联合特征向量 $E_t^{(i)}$ 与其生成时对应的原始意图推理文本 $I_t^{(i)}$ 具有一一对应关系。基于此，对于第 j 个潜在意图状态，提取所有被分配至该状态的原始意图文本，构成意图实例集合：

$$\mathcal{I}_j = \{I_t^{(i)} \mid s_t^{(i)} = j\}, \quad (4-9)$$

其中 $s_t^{(i)}$ 由公式 4-7 确定。

考虑到簇内意图在表达层面仍可能存在冗余与噪声，本文进一步以聚类中心 μ_j 为参考，在谱空间中筛选其邻域内的代表性样本，得到精炼的原型候选集合：

$$\mathcal{I}_j^{\text{proto}} = \{I_t^{(i)} \in \mathcal{I}_j \mid \|E_t^{(i)} - \mu_j\|^2 \leq \epsilon_j\}, \quad (4-10)$$

其中 ϵ_j 控制用于语义归纳的样本规模，为簇内距离分布的第 q 分位数，仅保留距离小于该阈值的样本用于语义归纳。该策略确保所选文本来自簇内的高密度核心区域，从而提升原型语义的一致性与稳定性。随后，引入大语言模型作为语义归纳器，对集合 $\mathcal{I}_j^{\text{proto}}$ 中的多条意图文本进行联合分析，抽象其共现的认知结构与决策取向，生成对应潜在意图状态 j 的语义原型描述 $\hat{I}_j$ 。该语义归纳过程仅用于对统计意图的离线解释，用于进一步对意图时序变化的分析作为基础。

通过上述步骤，潜在认知状态 j 在数学上由谱聚类中心 μ_j 所定义，在语义上则由意图原型文本 $\hat{I}_j$ 所刻画，从而实现从原始语言意图 $I_t^{(i)}$ 到可解释离散认知状态的完整映射。

4.2.3 时序演化分析

在完成个体意图的联合表征与潜在意图离散化之后，Agent 的意图已被统一映射为有限状态空间中的离散序列。本节在群体尺度上刻画这些意图状态的时序演化规律，并分析其与实际行为结果之间的统计关联，从而揭示宏观涌现现象背后的动态微观机制。

本文采用一阶马尔可夫模型（First-order Markov Model）对潜在意图状态序

列进行建模。通常情况下，Agent 的决策具有长程历史依赖性；但在第4.2.1节的提取步骤在 EMA 累积机制的作用下，历史信息已被压缩编码于当前特征表示中。因此，本节在离散状态层面采用一阶马尔可夫模型作为近似演化过程描述。

对于 Agent 的离散意图状态序列 $S^{(i)} = (s_1^{(i)}, \dots, s_T^{(i)})$ ，本节从宏观群体尺度出发，对全部 Agent 的意图状态转移进行统一统计建模。转移概率矩阵刻画的是群体层面的整体演化结构，用以揭示意图模式在系统层面的扩散与稳定机制，统计其在相邻时间步之间的状态转移频次，定义群体层面的意图转移计数矩阵 $C \in \mathbb{R}^{k_{clu} \times k_{clu}}$ ：

$$C_{uv} = \sum_i \sum_{t=1}^{T-1} \mathbb{I}(s_t^{(i)} = u, s_{t+1}^{(i)} = v), \quad (4-11)$$

其中 $\mathbb{I}(\cdot)$ 为指示函数。

对转移计数矩阵按行归一化，得到群体 Agent 意图的转移概率矩阵：

$$P_{uv} = \frac{C_{uv}}{\sum_{v'} C_{uv'}} = P(s_{t+1} = v | s_t = u), \quad (4-12)$$

矩阵 $\mathbf{P}$ 描述了不同潜在意图状态之间的转化倾向，是刻画群体 Agent 意图演化的核心对象。

为进一步分析不同意图在时间维度上的群体占比变化，定义时间步 t 下处于状态 j 的群体分布为：

$$D_t(j) = \frac{1}{N} \sum_i \mathbb{I}(s_t^{(i)} = j), \quad (4-13)$$

其中 N 为 Agent 总数。序列 $\{D_t\}_{t=1}^T$ 描述了不同意图模态在群体中的扩散、收缩与演化过程，可用于构建跨时间的意图流动图，从宏观层面直观呈现涌现结构的形成轨迹。

在此基础上，本文进一步建立潜在意图状态与实际行为决策之间的统计映射。Agent 在时间步 $t+1$ 所采取的离散行为输出表示为 $a_{t+1}^{(i)}$ 。该变量是由人群移动模拟过程中直接采集的可观测外显决策。通过采用 s_t 与 a_{t+1} 的时间错位对齐，旨在避免将行为结果反向解释为状态组成部分，从而切断同源相关带来的统计偏置。为准确刻画不同意图状态对后续行为模式的驱动效应，本节采用条件分布与显著性检验进行量化。具体而言，依据 Agent 所处的潜在意图状态 $s_t^{(i)} = j$ ，将整个群体在下一时刻的行为输出划分为 k_{clu} 个条件子集。针对系统中预定义的离散行为空间，统计给定意图状态下的行为条件概率分布： $P(a_{t+1} = y | s_t = j)$ 即计算处于意图状态 j 的 Agent 采取特定行为 y 的频数占比。该分布直观地刻画了不同意图组织形式下 Agent 的外显决策倾向。

通过上述条件分布与独立性检验，抽象的潜在状态获得了高度可解释的物理行为对照。这不仅严谨地证实了微观意图对宏观行为的驱动作用，更为后续分析群体如何通过意图演化陷入特定的涌现困境提供了直接的数据支撑，从而实

现了从微观认知表征到宏观行为涌现的完整闭环。

4.2.4 涌现机制分析

在完成潜在意图状态的抽象与时序演化过程构建之后,本节基于算法的结果进一步阐明如何利用上述模型分析意图状态随时间的演化规律,并揭示其在群体 Agent 中引发宏观涌现现象的微观机制。从时序演化视角来看,宏观涌现(如系统性的资源竞争或协同演化)往往并非由单一瞬时行为触发,而是源于某类特定意图状态在群体中的持续蔓延、相互转化,及其对外显行为选择结构的系统性重塑。因此,本节的涌现机制分析建立在两个相互衔接的层次之上:其一是潜在意图状态的时序演化结构分析,其二是意图状态与后续物理行为之间的条件驱动分析。




图 4-4 意图涌现机制分析框架

首先,意图的时序演化分析旨在重构群体层面的宏观意图流动路径。如图 4-4 所示,本节利用第 4.2.3 节构建的马尔可夫模型与转移概率矩阵 $\mathbf{P}$,刻画不同离散意图状态之间的统计转化关系。在该网络化表示下,具有较高自转移概率 P_{kk} 的状态对应于群体中容易陷入并维持的相对稳定意图模式;而具有显著跨状态转移概率的节点,则往往充当群体意图演化过程中的过渡态或触发态。通过分析这些高频转移路径与群体意图分布 $\{D_t\}$ 的时序变化,可以精准识别在宏观涌现现象爆发前夕,群体内部意图结构所经历的关键重组阶段,从而为涌现现象提供明确的微观意图演化起点。

然而,仅有意图状态的演化结构尚不足以构成完整的因果机制解释。为验证

潜在意图状态是否真正对宏观物理环境产生实质性影响，本文进一步分析意图状态与后续外显行为之间的条件驱动关系（见图 4-4 下半部分）。具体而言，利用第 4.2.3 节中提取的行为条件概率分布 $P(a_{t+1} | s_t)$ 与独立性检验结果，评估意图变化向行为输出的转化效率。当某一特定意图状态在满足以下两个条件时：一是在群体演化路径中占据核心位置，如占比持续上升或在关键转移路径中频繁出现，二是其条件发射概率显著改变了 Agent 的常规决策倾向，如触发高频的跨区移动或激进行为，该状态即可被严格界定为连接微观意图推理的思维链与宏观群体涌现的关键机制节点。

通过将意图状态的时序马尔可夫分析与意图-行为的条件概率映射相结合，本文实现了从底层意图结构到外显行为分布重塑，再到群体宏观现象涌现的完整机制分析闭环。该分析框架不依赖于外部强加的行为规则假设，而是完全基于 Agent 内部生成的思维特征与实际执行的物理动作之间的统计事实，为解析复杂系统中的涌现现象提供了一条可追溯、结构化的微观剖析路径。

4.3 实验系统构建

为验证本章提出的基于意图模型的群体 Agent 机制分析方法的有效性，本文选取第三章第 3.4.2.2 节中 2019—2021 年模拟过程中出现的群体行为现象作为研究对象。在多类型角色 Agent 并存的情境下，骑手 Agent 在 2021 年最后一个月表现出显著的空间聚集特征，因此本文以该骑手 Agent 聚集现象为案例，对其形成机制进行系统分析。第三章已构建包含骑手 Agent 与用户 Agent 在内的完整 O2O 服务平台模拟系统，并在该系统中复现了骑手空间聚集现象。因此，本章在第三章构建实验环境基础上，以骑手聚集现象为切入点，运用本章提出的意图层机制分析方法对其微观认知驱动机制进行进一步验证。

骑手从业者在平台上接单和工作，可以自由决定工作时间、地点、休息休假，甚至能够决定劳动供给与收入水平，这赋予了他们一种工作自主感。事实上，作为数据驱动型的互联网平台，通过详细记录从业者行踪的各种细节，来完成对从业者的管理。针对这种新的经济模式以及平台对劳动过程的控制策略，图4-5给出了 O2O 服务生态系统的运行逻辑，并以此为基础搭建实验沙盘，以方便进行各类算法治理实验。

“内卷”概念最初用于描述在资源约束条件下，社会经济系统出现的高投入、低产出甚至发展停滞的结构性状态。在后续社会科学研究中，该概念逐渐被用于刻画有限资源环境中个体或群体过度竞争所导致的效率下降现象。在服务生态系统语境下，这种状态通常表现为竞争强度上升，但单位投入产出比下降以及整体福利水平未能同步提升。




图 4-5 互联网 O2O 服务生态的实验沙盘设计

结合第三章对 2019 年-2021 年模拟过程中骑手空间聚集现象，本文提出如下机制性假设：骑手聚集并非单纯源于理性区位选择，而可能是在资源约束与竞争强化条件下，群体策略互动所产生的结构性结果。在 O2O 外卖平台场景中，骑手的空间移动并非独立决策结果，而是基于接单、派单与收益竞争等经济决策过程之中。空间聚集现象在本质上是骑手在资源约束与零和竞争条件下形成的接单策略与收益预期在空间维度上的外在映射。因此，对接单行为与收益结构的分析并非偏离移动问题，而是对移动行为生成动因的机制层追溯。基于此，实验将订单决策行为视为移动行为的认知驱动基础，在意图层面对其演化过程进行刻画，以解释空间聚集涌现的形成机制。

本章所使用的“内卷”是一个操作化的机制分析概念，并非价值判断术语。具体而言，本章将其界定为：在资源受限与零和竞争环境中，由群体认知意图结构逐步收敛所驱动，并通过空间聚集强化、竞争密度提升以及单位收益边际递减等行为特征所体现的一种群体演化状态。

因此，为系统分析该现象的形成机制及其演化路径，本章在第三章构建的意图对齐多 Agent 模拟系统基础上，引入本章中的认知意图机制分析方法，对骑手群体在长期交互过程中的意图收敛轨迹与行为映射结构进行系统刻画，从而构建“微观认知—中观行为—宏观结构”的机制解释链条。

在第三章构建的框架基础上，本章引入平台 Agent，用以记录与分析外卖服务过程中的订单生成、信息广播与资源分配过程。与具备认知推理能力的用户与骑手 Agent 不同，平台 Agent 不进行意图生成，而是作为规则驱动的协调节点，维护订单集合与在线骑手状态，并采用开放式订单发布机制。通过构建该多 Agent 交互系统，本文旨在分析在统一认知决策内核下，平台制度结构如何影响个体策略选择，并进一步诱发群体层面的涌现现象。

平台 Agent 负责维护平台化服务系统中的订单与骑手状态信息，并为骑手 Agent 提供订单发布与状态同步等基础支撑功能。在本研究中，平台 Agent 不进行认知意图推断，而是采用开放式订单发布机制，由骑手 Agent 根据自身意图与状态自主完成接单决策。平台在时刻 t 的系统状态定义为：

$$s_p^t = \{O^t, R^t\}, \quad (4-14)$$

其中， O^t 表示平台当前发布的待接订单集合， R^t 表示处于在线状态的骑手 Agent 集合。在每一时间步，平台 Agent 的行为被定义为订单发布与状态更新过程，具体形式为：

$$a_p^t = \text{Publish}(O^t), \quad (4-15)$$

平台仅负责将订单信息广播至骑手 Agent，并在骑手完成接单后对订单与骑手状态进行同步更新。

4.4 实验设计与结果分析

本节旨在验证本章所提出的意图驱动涌现机制分析的有效性，并通过实验回答以下三个研究问题 (Research Question, RQ)：

RQ1：本文提出的基于意图的机制分析方法，是否能够有效刻画群体 Agent 认知意图的涌现结构及其动态演化过程？

RQ2：意图演化结果能否与行为演化过程形成可解释的跨层耦合结构，从而构建“意图—行为—宏观涌现”之间的机制性分析框架？

RQ3：所提出的涌现机制分析方法是否具有跨场景适用性，即在不同城市人群移动行为模拟框架下仍能保持稳定的解释能力？

4.4.1 实验设计

本章实验在第三章构建并完善的多 Agent O2O 外卖平台服务平台基础上展开。第三章已在该环境中识别出骑手在空间层面的聚集涌现现象，但这一现象的涌现机制有待分析。基于前述分析，本文提出假设：骑手聚集可能是群体在零和竞争与资源受限条件下发生“内卷化”演化的外在空间表征。为检验这一假设，在模拟环境框架下，引入本章意图层机制分析方法，对骑手 Agent 在长期交互过程中的认知意图演化、行为映射结构及其宏观结果进行系统刻画。通过构建“意图—行为—宏观指标”的跨层分析框架，验证骑手聚集是否源于群体意图结构向低收益认知模式的收敛，并由此导致高消耗、低回报的内卷状态。

本章实验基于第三章仿真结果中选取的最后 30 天数据，共获得 3002 条意图推理文本 I_t 。文本嵌入采用 all-MiniLM-L6-v2 编码器生成。潜在意图状态通过

K-means 聚类获得，并在 $k \in [2, 8]$ 范围内通过 silhouette score 选择最优簇数，最终设定 $k_{clu} = 4$ 。簇内语义原型筛选分位数设为 $q = 0.2$ 。意图表示构建过程中，指数移动平均平滑系数设为 $\gamma = 0.9$ ，谱特征维度设为 $k_{eig} = 16$ ，语义向量经 PCA 降维至 $d_{sem} = 32$ 维。语义原型归纳采用 DeepSeek-v3.2 模型，temperature 设为 0.3。主要实验参数如表 4-1 所示。

表 4-1 主要实验参数设置

参数	含义	取值
I_t	意图推理文本数量	3002
k_{clu}	聚类数量	4
q	原型样本分位数	0.2
γ	EMA 平滑系数	0.9
k_{eig}	谱特征维度	16
d_{sem}	语义降维维度	32

围绕 RQ1，实验一旨在验证所提出意图机制分析方法在刻画群体认知意图涌现与演化过程中的有效性，重点检验该方法是否能够在长期交互情境下，从微观个体 Agent 的连续决策轨迹中识别并重构群体层面的意图结构生成、演化与收敛过程。具体而言，首先构建并量化骑手 Agent 的内卷指标，以刻画系统在资源约束条件下的竞争强度与收益结构变化；随后，在模拟运行的不同时间阶段提取个体 Agent 的结构化意图表征，通过聚类分析识别潜在意图类型，并基于意图转移关系构建动态演化模型，结合意图占比的时间变化对群体意图结构的集中化趋势进行刻画。在此基础上，引入时间尺度分析，检验意图演化过程是否呈现出稳定的阶段性特征与结构性跃迁，从而系统评估本文方法对群体意图涌现现象的识别能力与动态刻画能力。

围绕 RQ2，实验二进一步构建意图、行为与宏观现象之间的跨层关联分析框架，检验是否能够通过“意图-行为-涌现现象”的连续分析，对涌现现象形成完整的机制性解释链。具体做法是：在意图演化分析的基础上，对 Agent 的外显行为分布与结构特征进行统计分析，比较行为空间与意图空间在演化节奏与分布形态上的差异；进一步结合意图-行为相关性分析，考察在相同行为模式下，不同意图状态是否对应显著不同的长期收益与工时演化趋势，并分析这些差异如何在长期累积中映射为宏观层面的内卷结果。通过该分析，验证意图是否能够作为连接微观行为与宏观涌现现象的关键中介变量，从而弥合单纯依赖行为统计所面临的解释断层。

围绕 RQ3，实验三引入对比实验设计，选取 LLMOB^[63] 与 COPB^[21] 两种具

有代表性的 Agent 架构作为基准模型，并以两种 Agent 架构中的意图推理链设计机制作为对比对象，在相同实验环境与参数设置条件下开展对照模拟实验。该部分旨在从普适性验证，考察在不同 Agent 架构下，意图分析框架是否均能捕捉到群体意图演化趋势，从而评估该机制分析框架在不同 Agent 架构下的稳定性与解释一致性。

4.4.2 实验分析

4.4.2.1 意图演化与宏观涌现现象分析

本小节重点分析系统运行过程中宏观现象的演化特征，并基于本章提出的意图机制分析方法，探讨其背后的形成机制。




图 4-6 实验内卷程度分析

图 4-6 展示了模拟周期内配送员群体 Agent 的核心生存指标演变趋势。模拟过程中，系统表现出显著的内卷化特征。随着模拟天数的增加，尽管配送员的平均工时（紫色虚线）呈现显著上升趋势，从约 4 小时激增至 5.5 小时以上，但其实际时薪（橙色实线）却遭遇了断崖式下跌，从初始的 5 元/小时跌至 1 元/小时左右。这种“高投入-低回报”的现象表明系统已进入资源匮乏陷阱。物理环境的恶化构成了强大的进化压力，迫使 Agent 必须放弃早期的随机或理想化策略。原有的高时薪生存模式失效，是驱动后续认知层面发生剧烈分化的根本动力。

为分析内卷的涌现现象，表 4-2 展示了通过第 4.2.2 节中的语义分析方法对聚类簇所识别的四类意图簇进行了语义化分析。该表从 Agent 的认知假设与决策取向出发，对每一类意图给出了简要描述，用于明确不同意图在决策逻辑层面的差异。

表 4-2 意图簇的语义描述

意图标签	意图描述
悲观竞争	在对环境竞争强度进行评估后, Agent 判断边际收益提升空间有限, 由此在意图推理中降低效率追求, 转而强化风险规避。
稳健优化	在评估环境仍存在机会的前提下, Agent 于意图生成过程中权衡收益与成本, 通过筛选策略与控制投入形成效率提升的意图。
现状维持	在对环境变化感知较弱或收益差异不显著的判断下, Agent 在推理过程中优先调用既有经验路径, 维持既定决策模式。
本地深耕	在对特定区域或策略模式形成稳定正反馈预期的基础上, Agent 在意图推理中强化局部投入与持续累积, 形成长期聚焦的稳定化决策取向。

具体而言,“悲观竞争”意图对应于一种以环境饱和评估为前提的认知推理路径。当 Agent 在情境判断中将竞争强度与资源约束评估为高度紧张,并预测边际收益提升空间有限时,其意图生成过程中会降低收益最大化目标的权重,转而强化风险控制与生存稳定目标,从而形成以规避不确定性为核心的决策取向。“稳健优化”意图则体现为另一种不同的环境评估结果。当 Agent 在认知推理中识别出环境中仍存在可利用的结构性机会时,其在收益预期与成本约束之间进行权衡,通过强化成本控制与策略筛选权重,生成审慎条件下的效率提升意图。这一推理路径并非激进扩张,而是在稳定性约束下的理性优化。“现状维持”意图源于对环境变化幅度与收益差异判断较弱的意图状态。当 Agent 在推理过程中未检测到显著的结构性变化或潜在增益时,其更倾向于调用既有经验路径,维持既定决策模式,从而形成路径依赖型的意图结构。该类意图体现的是认知惯性在决策生成中的主导作用。最后,“本地深耕”意图反映了一种基于局部正反馈强化的意图推理模式。当 Agent 在特定空间区域或行为模式中持续获得稳定回报时,其在意图生成过程中提高对局部信息与经验记忆的权重,弱化对全局搜索的关注,进而形成长期聚焦的稳定化决策取向。这一推理结构揭示了系统内部空间异质性与累积效应对意图演化的影响。

总体而言,这四类意图从不同侧面反映了 Agent 对环境竞争程度、可优化空间与风险收益结构的主观认知差异,为后续从微观意图演化解释群体行为模式及宏观异常涌现现象提供了语义基础。

同时,基于谱嵌入的意图聚类结果如图 4-7 所示,图中 PC1 和 PC2 为联合嵌入向量的二维 PCA 投影,用于可视化展示。聚类结果用于刻画城市人群移动模拟过程中骑手 Agent 的意图分布结构及其随时间的演化特征。图 4-7(a)展示了




图 4-7 意图聚类分析

完整模拟周期（01–30 天）内的总体意图分布情况。从联合嵌入空间可以观察到，骑手 Agent 的意图在特征空间中形成了四个稳定的聚类区域，对应于“悲观竞争”、“稳健优化”、“现状维持”和“本地深耕”四类认知策略。

从嵌入空间的拓扑结构上看，各类意图在二维 PCA 投影空间中呈现出较为清晰的分离趋势，不同意图簇在空间位置上整体保持一定距离，同时类内样本呈现出一定程度的离散分布。这表明所构建的语义–统计联合表征能够较好地刻画不同意图模式之间的差异。其中，“本地深耕”意图在 PC1 方向上位于负向区域，与其他策略在空间位置上保持明显间隔，反映出该类意图在认知结构与决策逻辑上的相对独立性。

为进一步观察意图结构的动态变化过程，图 4-7(b)–(d) 分别给出了模拟初期（第 01 天）、中期（第 15 天）与后期（第 30 天）的分布情况。结果显示，在模拟初期，Agent 主要集中于“现状维持”和“本地深耕”两类保守策略区域；随着模拟推进，个体逐渐偏离初始区域并在嵌入空间中发生迁移；在后期阶段，群体意图逐步收敛为以“稳健优化”和“悲观竞争”为主导的两类核心模式。该演化

轨迹表明，在持续的模拟过程中，骑手群体 Agent 意图推理结构经历了从早期探索到后期收敛的动态调整过程。




图 4-8 意图涌现时序分析

为了进一步刻画意图状态的演化过程，图 4-8 通过桑基图形式展示了意图时序演化分析的结果。该图描绘了意图状态从第 01 天、到第 15 天，再到第 30 天的演化路径及其对应比例变化。从初始状态来看，第 01 天时系统中仅存在两种相对保守的探索意图：“本地深耕”占据绝对主导，约 80%，“现状维持”占比为 20%。随着仿真推进至第 15 天，群体意图发生了剧烈的结构性重组，早期的两类策略被彻底放弃，系统演化为以“稳健优化”为主，约 70%、“悲观竞争”为辅（30%）的新格局。这反映出个体在感知到环境竞争压力后，普遍尝试通过理性的全局优化方式来应对挑战。

然而，这种基于理性的集中状态并未能持续。进入最终阶段（第 30 天），大量原本采取“稳健优化”的 Agent 发生意图降级，桑基图中出现了规模庞大的向下转移数据流。最终，系统意图分布呈现出极端的单向收敛：“悲观竞争”策略的占比飙升至 92%，成为系统中的绝对主导状态，而坚持“稳健优化”的个体仅剩约 7%。上述演化过程说明，“悲观竞争”并非短期扰动或情绪性选择，而是在高压竞争环境中，群体认知经历“探索—优化—妥协”后逐步显现出的稳定策略终态。

图 4-8 不仅直观展示了策略的分布变化，更深刻揭示了系统陷入“内卷性贫困增长”的微观机制。在模拟过程中，日均订单总量等宏观资源保持恒定。桑基

图中由“稳健优化”向“悲观竞争”的大规模跨状态流量，标志着群体策略从“价值优先”向“生存优先”的无奈降级。转化为“悲观竞争”意图的 Agent 放弃了对高时薪或优质订单的筛选，转而采取“来单即接”、盲目延长工作时间等低效高频策略，以对抗被淘汰的风险。

综上所述，基于意图演化的分析表明，系统中“内卷”现象的出现，本质上源于 Agent 认知目标在长期竞争压力下的结构性退化。在资源供给受限且竞争持续加剧的环境中，个体的主导意图逐步由以收益效率为导向的“稳健优化”，单向塌缩为以风险规避和生存维持为核心的“悲观竞争”。这一转变并非短期扰动，而是通过意图转移流向所揭示的必然演化结果。随着“悲观竞争”占据主导地位，系统整体的决策目标从“如何提高单位投入产出”退化为“如何避免无单可接”，从而在宏观层面涌现出平均收益持续下降、工作强度不断上升的恶性内卷趋势。由此可见，高工时、低收益的宏观现象并非仅由外部环境直接设定，而是群体意图结构在长期博弈中发生单向收敛所诱发的涌现结果。

4.4.2.2 意图-行为-涌现现象机制分析

在前述意图演化分析的基础上，本小节进一步从行为空间出发，考察仅依赖外显行为统计是否能够反映系统演化过程中的结构性变化。具体而言，通过统计 Agent 在仿真过程中的主要行为类型，并结合意图-行为关联分析，构建“意图—行为—宏观涌现”的分析框架，从而评估基于行为统计的方法在解释群体内卷现象方面的效果。




图 4-9 行为时序分析

图 4-9 展示了基于 Agent 行为频率统计构建的行为桑基图，其中包含接单、商区转换、休息与保持策略等主要行为类型。从整体分布来看，行为空间在整个

仿真过程中呈现出相对稳定的统计特征。在模拟初期阶段，“商区转换”行为已占据主导地位，其比例约为 68%；随着模拟推进，该比例仅缓慢上升至约 76%，整体变化幅度有限。相比之下，其他行为类型（如接单与休息）的比例在不同阶段均保持在较小区间内波动。结合第4.4.2.1中的图4-6中内卷指标的显著变化对比表明，从宏观行为频率的角度看，系统在较早阶段便呈现出近似稳定的统计结构，难以直接反映后续演化过程中潜在的结构变化。




图 4-10 意图演化相关性及其意图-行为关联分析

结合第4.4.2.1节的意图演化过程结果可以发现，尽管行为空间变化有限，Agent 在意图面经历了较为明显的策略重组与分化过程。为进一步验证所提出方法在刻画意图结构及其宏观演化机制方面的有效性，本节计算了意图演化过程中的状态转移概率以及意图-行为的条件概率映射关系。图 4-10 给出了相应的量化结果。其中，图 4-10(a) 展示了意图状态在相邻时间步 $t \rightarrow t+1$ 之间的马尔可夫转移矩阵，用于刻画不同意图在时间演化过程中的稳定性及其转移方向；图 4-10(b) 则给出了在给定当前意图状态下，Agent 在下一时刻采取具体物理行为的条件概率分布。

从意图的时间演化结构来看，如图 4-10(a) 所示，意图转移矩阵呈现出明显的非对称结构，表明系统演化过程中存在较为清晰的收敛趋势。其中，“悲观竞争”与“稳健优化”表现出较高的自维持概率（分别为 0.58 和 0.55），说明这两类状态在系统演化过程中具有较强的稳定性，构成群体意图结构中的核心模式。相比之下，模拟初期出现的探索性策略则表现出较强的不稳定性。例如，“现状维持”状态分别以 0.38 和 0.32 的概率向“悲观竞争”和“稳健优化”发生转移；即便是具有一定自循环概率的“本地深耕”策略，也存在向“悲观竞争”（0.23）与“稳健优化”（0.23）转移的明显趋势。上述结果表明，在持续的环境竞争与策略博弈作用下，群体意图结构逐渐由多样化探索状态向少数稳定策略模式收敛。

进一步结合图 4-10(b) 的意图-行为条件概率可以发现,不同意图状态在行为层面的执行结构呈现出明显的策略分化。其中,“稳健优化”“悲观竞争”以及“现状维持”三类意图均表现出较高的“商区转换”概率(分别为 0.71、0.68 与 0.61),表明在这些策略下,Agent 更倾向于通过跨区域移动进行机会搜索。相比之下,“本地深耕”意图则呈现出截然不同的行为模式:其触发“接单”行为的概率达到 0.50,而“商区转换”的概率仅为 0.37,说明该类策略更倾向于在熟悉区域内直接完成订单匹配,而非通过频繁移动进行搜索。

这一差异表明,群体中的意图结构实际上对应着两种不同的行为决策逻辑:一类策略通过空间迁移扩大搜索范围,以提高潜在订单机会;另一类策略则依赖局部经验与信息优势,在相对固定区域内直接执行接单行为。结合图 4-9 的行为统计可以进一步发现,随着模拟演化过程中“稳健优化”与“悲观竞争”等搜索型策略逐渐占据主导地位,群体整体的“商区转换”行为比例也随之持续上升,从而在宏观层面表现为骑手群体移动频率增加的行为特征。




图 4-11 基于意图聚类与行为分类的骑手单位时间收益对比

为验证本文所提出意图分析框架在刻画 Agent 生存状态方面相较于传统行为统计方法的解释增益与互补价值,本节对基于认知意图聚类(图 4-11a)与基于外显行为分类(图 4-11b)的平均单位时间收益分布进行了对比分析。通过双重视角的交叉检验,可以更系统地揭示物理行为表现与其背后认知生成机制之间的结构关联。

从外显行为视角(图 4-11(b))来看,不同行为类型对应明显不同的即时收益效率。其中,“商区转换”行为的平均单位时间收益最低,说明频繁的跨区域移动会显著增加时间成本并降低收益效率;“接单”行为的收益处于中等水平;而“保持策略”虽然具有最高平均收益,但波动也较大。该结果能够刻画不同物理

行为的效率差异,但仍停留于行为结果层面,难以解释群体为何在长期演化中趋向于低收益的行动组合。

引入意图视角(图 4-11a)后,可以观察到更为清晰的收益分层结构。结果显示,“本地深耕”意图对应最高且相对稳定的平均收益,表明在竞争压力较高的环境中,强化局部信息利用与经验累积具有显著优势;“现状维持”意图亦呈现较高收益,但伴随较大的方差,反映出其对环境波动具有较强敏感性。相比之下,“悲观竞争”与“稳健优化”意图对应的平均收益显著下降,其中“稳健优化”收益水平最低且波动较小,说明在当前竞争环境下,频繁依赖跨区域搜索并未显著提升收益水平,反而可能导致稳定但较低收益结构。

综合两种分析视角可以发现,行为统计与意图分析在解释层面形成了明显互补:行为统计刻画了行动层面的资源消耗与收益表现,而意图分析则揭示了驱动行为选择的认知策略结构。结合前文的意图转移结果可以看到,当大量 Agent 在竞争压力下逐渐收敛至“悲观竞争”与“稳健优化”等意图状态时,其行为映射在执行层面表现为“商区转换”概率的系统性提高。由于该类行为本身具有较低的单位时间收益,这一变化最终在宏观层面表现为高移动消耗与低收益并存的群体结构特征。

综合分析表明,模拟过程中骑手 Agent 的内卷现象并非由某一具体行为模式直接导致,而源于群体认知意图在演化过程中的结构性变化。随着竞争压力持续增强,Agent 的决策意图逐渐由效率导向的策略转向以生存维持为目标的“悲观竞争”等模式。这一变化并未显著改变行为类型的整体分布,而是改变了相同行为的决策逻辑与执行方式,使得接单与移动等行为逐渐演化为高频但低效率的同质化执行过程。由此可见,仅依赖行为空间难以解释模拟过程中内卷现象的演化机制,而将意图作为连接个体决策与宏观结果的中介变量,对于理解多 Agent 系统中的内卷涌现具有关键作用。

4.4.2.3 对比实验

为验证本文提出的意图分析框架的跨架构适用性,并排除实验结果对特定 Agent 架构的依赖性,本节选取 LLMOB 与 COPB 两种具有代表性的 Agent 架构开展对比实验。

在开展跨架构对比分析之前,有必要说明不同 Agent 架构下意图簇语义的一致性。由于各架构在生成机制与提示结构上存在差异,其聚类后形成的意图文本在表述风格与语义细节上并非完全相同。为确保比较的可比性,本文基于 LLM 语义归纳方法,对不同架构下的意图簇进行语义抽象与概念对齐分析。

归纳结果表明,尽管不同架构在具体措辞与侧重点上存在一定差异,但在核心认知评估逻辑(如竞争强度判断、收益空间预期与风险权重配置)层面具有稳

表 4-3 不同架构下意图簇语义特征对比

意图类别	LLMOB 意图描述	COPB 意图描述
本地深耕	未对齐：未出现可稳定分离的对应簇	强调利用局部优势降低风险与不确定性
稳健优化	在收益与成本之间进行动态权衡调整	在约束条件下进行策略搜索与路径优化
现状维持	延续既有路线与历史经验，减少调整频率	保持既定策略，避免不必要的策略变动
悲观竞争	在收益受限情境下强化竞争与资源争夺	以生存优先为目标，与他人竞争
工作生活平衡	更注重时间压力与生活节奏之间的平衡	未对齐：未出现可稳定分离的对应簇

定对应关系，因此可在抽象层面映射为统一的意图类别。

在统一实验环境与参数设置条件下，对不同架构下的意图演化轨迹及其与行为分布之间的关联结构进行系统比较分析，如图 4-12 所示。

首先，对比行为分布与意图结构的演化趋势。观察图 4-12(a) 与 (b) 所示的行为时序结果可以发现，与意图空间中所呈现的显著集中化趋势相比，行为空间在整个模拟周期内整体变化幅度较小，未出现明显的阶段性突变特征，表现出相对平缓的演化轨迹。

结合前文行为分析结果（见图 4-9），可以进一步发现，无论采用何种底层架构，在模拟初期，“商区转换”等高频移动行为已占据主要比例（约 68%），且随着系统演化推进，该类行为占比仅呈现有限幅度的渐进式上升（后期约 76%）。从行为频率分布的时间序列特征来看，整体变化趋势较为连续且缺乏显著结构转折。

之后，从意图时序演化的整体趋势来看，内卷式意图收敛过程在不同架构下表现出高度一致性。对比图 4-12(c) 与 (d) 可见，在模拟初期，两种架构下的 Agent 均以“本地深耕”策略为主（LLMOB 占比 60%，COPB 占比 73%），呈现相对稳健的区域策略选择；随着系统演化进入中期阶段，群体意图逐步转向“稳健优化”等全局策略探索；而在后期阶段，两种架构均出现明显的意图集中化趋势，并最终收敛至以“悲观竞争”为主导的低收益竞争模式。其中，LLMOB 架构下该意图占比达到 75%，COPB 架构下则达到 94%。

结合前一节对 TIMB 方法的意图涌现分析结果 4-8，无论是 LLMOB、COPB 还是 TIMB 架构，群体意图结构均呈现出高度一致的单向收敛趋势。具体而言，在经历初期的策略探索与阶段性的理性优化后，群体意图分布逐步向“悲观竞争”模式集中，并在后期阶段形成占主导地位的单一意图结构（如图 4-8 中意图




图 4-12 机制分析结果对比

占比达到 92%)。这一收敛过程在时间维度上表现为路径依赖特征，即一旦群体进入该竞争模式，其后续意图转移概率显著下降，呈现出结构性锁定趋势。

因此，上述结果表明，群体意图向以生存约束为导向、弱化价值探索的竞争模式收敛的过程，并非特定模型结构、提示词设计或参数随机扰动的偶然结果，表明在当前模拟环境与资源约束条件下，该竞争模式具有一定的结构性稳定性。这一跨架构的一致性结果为本文提出的“认知意图结构退化驱动宏观内卷形成”的机制假说提供了实证支持，同时表明所构建的意图驱动分析框架在不同 Agent 架构下均能够稳定识别群体认知收敛路径，从而体现出一定程度的跨模型适用性与机制解释能力。

综合不同架构下的行为分布与意图结构演化结果可以发现，两者在时间演化方向上呈现出一致趋势。从行为层面来看，高频移动行为在不同架构下均维持较高占比，并在后期阶段呈现缓慢强化趋势；而在意图层面，群体认知结构则逐步向以“悲观竞争”为代表的竞争导向策略集中。

这一跨层一致性表明，行为分布的渐进变化与意图结构的集中化过程在机制上具有稳定关联。更重要的是，该现象在 LLMOB、COPB 以及 TIMB 三种不同 Agent 架构下均得到复现，说明群体意图向竞争模式收敛的过程并非特定模型结构或提示词设计的结果，而是在相同环境约束条件下不同决策模型均可能产生的演化趋势。

4.5 本章小结

本章系统地介绍了一种基于意图演化的人类移动涌现机制分析方法。首先，围绕人类移动行为中的异常涌现现象，构建了一个从个体认知意图到群体行为再到宏观现象的跨尺度机制分析框架，并对其整体思想与分析目标进行了概述。随后，详细阐述了该方法的关键组成模块，包括个体意图追踪、意图谱式表征、潜在认知状态聚类以及群体层面的时序演化与意图—行为关联分析，系统说明了各模块在揭示涌现机制中的作用与实现方式。最后，通过在 O2O 服务生态等典型出行场景中的实验验证，结果表明，所提出的方法能够有效刻画群体认知状态的演化路径，识别驱动宏观异常涌现的关键意图结构，并在不依赖额外行为假设的前提下，为涌现现象提供清晰、可解释的机制支撑。

第 5 章 城市人群移动行为涌现机制分析系统

本章在前文研究工作的基础上,结合第三章提出的基于 Agent 意图建模的城市人群移动行为模拟方法,以及第四章提出的 Agent 意图驱动的城市人群移动涌现机制分析方法,围绕城市人群移动行为模拟与涌现机制分析的实际需求,设计并实现一个基于 Agent 意图推理的城市人群移动涌现机制分析系统。该系统以大语言模型驱动的 Agent 意图推理为核心,通过整合行为模拟、意图提取与群体机制分析等功能模块,实现从微观个体意图生成到宏观群体涌现现象分析的统一计算实验平台,从而为城市人群移动行为的模拟与机制研究提供可视化与可扩展的实验环境。本章内容将按照系统开发与实现的逻辑顺序展开:第 5.1 节首先对系统的功能需求与非功能需求进行分析,明确系统设计的目标与基本要求;第 5.2 节在需求分析的基础上给出系统总体架构设计,对系统的主要模块及其功能划分进行说明,并分析模块之间的交互关系;第 5.3 节进一步介绍系统核心功能模块的实现方法,包括 Agent 行为模拟模块、意图推理模块以及群体涌现机制分析模块的具体实现过程。

5.1 需求分析及开发环境

随着城市人群移动行为研究逐渐从轨迹统计分析转向复杂社会系统的计算实验研究,需要构建能够支持行为模拟与机制分析的实验平台。结合第三章提出的基于 Agent 意图建模的城市人群移动行为模拟方法以及第四章提出的 Agent 意图驱动的城市人群移动涌现机制分析方法,本文设计并实现一个城市人群移动涌现机制分析系统,为城市人群移动行为的模拟实验与机制研究提供统一的实验环境。

在系统功能方面,系统需要支持城市环境与个体 Agent 的建模,并模拟 Agent 在不同情境条件下的移动行为。通过引入基于大语言模型的意图推理机制,使 Agent 能够根据环境信息与历史记忆生成结构化移动意图,并在意图约束下完成行为决策与轨迹生成。同时,系统能够记录模拟过程中产生的行为数据与意图数据,为后续群体行为分析提供基础;在群体机制分析方面,系统提供对 Agent 意图状态进行提取与分析的功能。具体而言,通过对群体 Agent 的意图进行向量化表示,并结合聚类方法识别典型意图模式,同时利用时序建模刻画意图状态的演化过程,从而分析其与群体移动行为及宏观涌现现象之间的关系;在非功能需求

方面，系统需要具备良好的可扩展性与稳定性，以支持大规模 Agent 的并行模拟与长时间演化实验。同时系统应具有较高运行效率与模块化结构，使行为模拟、意图推理与机制分析模块能够协同运行，并便于后续扩展与优化。

系统整体采用前后端分离架构，以提高系统的可扩展性与维护性。在前端实现方面，系统基于 Vue3 框架构建用户交互界面，并结合 Three.js 实现城市环境的三维可视化展示，用于动态呈现 Agent 在城市空间中的移动过程及群体行为演化情况。在后端实现方面，系统采用 Python 作为主要开发语言，并基于 Repast4Py 构建 Agent-Based Modeling 仿真框架，实现 Agent 的状态更新、行为决策与群体交互过程。同时，系统结合大语言模型进行意图推理，其中通过 OpenAI 库实现模型接口调用，并利用 Transformers 库完成模型加载与推理过程。在数据管理方面，系统采用 MySQL 数据库对模拟过程中产生的轨迹数据、意图数据以及实验结果进行存储与管理。开发过程中主要使用 Visual Studio Code 作为开发工具，以支持系统代码编写与调试。

5.2 系统架构设计




图 5-1 系统架构图

本文构建的城市人群移动涌现机制分析系统主要包括界面层、应用层、模型层和数据层四个部分，系统整体架构如图5-1所示。

界面层：界面层为用户提供与系统交互的入口，主要负责系统信息的输入与输出。系统前端基于 Vue3 框架实现用户交互界面，并结合 Three.js 构建城市环境的三维可视化场景，用于展示 Agent 在城市空间中的移动过程以及群体行为的演化情况，并对群体行为的涌现机制分析结果进行可视化展示。通过可视化界

面，用户能够直观观察模拟过程中 Agent 的行为变化和群体涌现现象。

应用层：应用层负责系统的核心业务逻辑处理，是连接界面层、模型层与数据层的重要中间层。该层主要包括模拟控制模块、任务调度模块以及机制分析模块等。应用层接收界面层传来的用户请求，对模拟任务进行解析与调度，并调用模型层完成 Agent 行为模拟与意图推理计算。同时，对模拟过程产生的数据以及群体机制分析结果进行处理与整合，并将最终结果返回界面层进行可视化展示。

模型层：模型层是系统的核心计算模块，主要负责 Agent 行为模拟与意图推理计算。系统基于 Repast4Py 构建 Agent 模拟框架，实现 Agent 的状态更新、环境交互以及移动行为决策过程。在认知决策方面，系统引入大语言模型进行意图推理，并加载第三章中通过 DPO 方法训练得到的意图推理模型，用于生成结构化的认知意图推理链。模型推理过程基于 Transformers 库完成模型加载与推理计算。通过上述机制，模型层能够实现 Agent 的认知意图生成与行为规划，为群体移动行为模拟与后续机制分析提供基础。

数据层：数据层负责系统数据的存储与管理。系统采用 MySQL 数据库存储模拟过程中产生的轨迹数据、真实轨迹数据、Agent 状态数据以及意图数据，并为应用层提供数据读取与写入接口。通过数据层的支持，系统能够对模拟过程进行记录，并为后续群体行为分析与涌现机制研究提供数据基础。

5.3 系统运行流程

系统整体运行流程如图 5-2 所示。首先，用户通过系统界面设置模拟参数并启动城市人群移动行为的 Agent 模拟任务，包括模拟数据、模型参数等运行配置。界面层将用户请求传递至应用层的模拟控制模块，模拟控制模块对任务进行解析，并通过任务调度模块调用模型层执行模拟过程。在模型层中，系统基于 Repast4Py 构建 Agent 仿真环境，实现 Agent 的状态更新、环境交互以及移动行为决策。在决策过程中，Agent 通过调用基于大语言模型的意图推理模块生成当前时刻的移动意图，并据此完成行为规划。

在模拟过程中产生的轨迹数据、Agent 状态数据以及意图数据通过数据读写接口写入 MySQL 数据库。应用层的涌现机制分析模块对模拟数据进行统计与分析，从而识别群体行为的演化模式与涌现机制。最终，分析结果返回至界面层，并通过三维城市可视化界面进行展示，使用户能够直观观察 Agent 行为演化过程及其群体涌现现象。




图 5-2 城市人群移动仿真系统运行流程图

5.4 系统效果展示

为验证所构建的面向城市人群移动行为涌现机制分析的多 Agent 计算实验平台的可用性与功能完整性，本文对系统运行界面与核心功能模块进行展示。系统支持仿真环境配置、Agent 与大语言模型参数设置以及群体行为机制分析等功能，通过可视化界面为用户提供完整的实验配置与结果分析流程。

如图 5-3 所示，系统提供了 Agent 与大语言模型参数配置界面。用户可以在该界面中设计 Agent 主体，并配置大语言模型相关参数，包括模型调用方式、推理策略以及扩展行为参数等。通过该模块，系统能够将大语言模型嵌入到 Agent 决策过程中，使 Agent 在模拟环境中能够基于认知意图进行行为决策，从而实现基于认知推理的移动行为生成机制。

在完成 Agent 与模型参数配置后，系统进入城市人群移动行为模拟运行阶段，并通过可视化界面对模拟过程进行实时展示。系统基于三维城市环境构建模拟场景，对城市空间结构与道路网络进行建模，并在此基础上模拟 Agent 在城市






图 5-3 Agent 与大语言模型参数配置界面


环境中的移动与交互行为。在模拟运行过程中，系统能够动态更新群体状态信息，并通过可视化界面展示 Agent 的移动轨迹与群体行为变化。同时，系统支持对 Agent 之间的交互关系进行可视化展示，以刻画群体行为在空间网络中的演化过程，整体的运行系统如图5-4 所示。




(a) 3D城市建模



(b) 群体状态更新



(c) Agent 移动出行可视化



(d) Agent 交互过程可视化

图 5-4 模拟运行界面

在实验运行完成后，系统提供机制分析与结果展示界面，对模拟过程中产生的 Agent 行为数据与认知意图数据进行统计分析与可视化展示。如图 5-5 所示，系统能够对模拟过程中生成的意图序列、移动行为轨迹以及群体演化过程进行综合分析，并通过多种可视化方式呈现分析结果。具体而言，系统首先对 Agent



图 5-5 群体出行意图机制分析界面

在模拟过程中形成的认知意图进行结构化分析，从群体层面识别具有代表性的意图模式，以刻画不同阶段群体决策策略的变化特征；随后进一步分析认知意图与实际行为之间的关联关系，通过构建思维—行为关联结构，揭示不同类型意图在空间行为选择中的影响作用，从而从微观认知层面理解 Agent 行为模式的形成机制；在此基础上，系统对群体行为随时间的演化过程进行可视化展示，通过展示不同阶段群体行为结构与策略分布的变化情况，刻画群体行为从初始状态到稳定结构的动态演化路径。通过上述分析过程，能够从认知意图层面对群体移动行为的形成过程进行解释，并进一步分析群体行为涌现现象的形成机制。

5.5 本章小结

本章在前文提出的城市人群移动行为模拟方法与涌现机制分析方法基础上，设计并实现了一个基于 Agent 意图推理的城市人群移动行为涌现机制分析系统。系统采用前后端分离架构，前端基于 Vue3 与 Three.js 实现交互与可视化展示，后端基于 Python 与 Repast4Py 构建 Agent 仿真环境，并结合大语言模型完成 Agent 意图推理过程，同时通过 MySQL 数据库实现模拟数据与实验结果的存储管理。该系统能够支持城市人群移动行为模拟、意图分析与群体行为机制研究，为计算实验方法提供可扩展的实验平台与可视化分析环境。

第6章 总结与展望

6.1 论文总结

本论文发现现有的城市人群移动行为研究普遍忽视了个体出行决策背后的认知意图演化过程。大多数方法将移动行为视为对环境状态的直接响应,或仅通过轨迹统计分布进行拟合,而未考虑个体在长期出行过程中基于经验积累与情境判断所形成的动态意图推理机制。此外,现有涌现分析方法通常停留在宏观行为统计层面,难以刻画微观认知如何通过群体交互逐步放大并演化为宏观移动模式,缺乏从意图到行为再到涌现的跨尺度机制解释框架。为此,本文首先创新性地构建了一个基于认知意图建模的城市人群移动行为模拟框架,在 Agent 内部显式引入结构化意图推理模块,并结合人类偏好优化算法对大语言模型进行对齐,使个体在不同情境条件下生成符合人类决策逻辑的意图推理链。然后,针对现有移动模拟方法难以在行为合理性与认知一致性之间取得统一的问题,设计了一个包含情景记忆、认知意图与空间选择机制的完整 Agent 决策结构,实现从认知意图到移动行为的可解释映射过程。接着,为进一步揭示群体层面的涌现形成机制,提出了基于意图聚类与时序演化建模的群体机制分析方法,通过对个体意图状态的抽象与转移分析,建立微观认知演化与宏观群体移动模式之间的动态关联。最后,本文基于东京真实出行数据集以及 O2O 外卖平台场景构建实验系统,对所提出方法进行了系统验证。实验结果表明,本文的意图驱动模型在保持轨迹统计一致性的同时,有效提升了意图预测准确度与长尾场景泛化能力,并能够从认知层面解释群体移动涌现现象的形成机制。具体来说,本文的主要工作如下:

(1) 构建了基于认知意图建模的城市人群移动行为模拟框架在传统移动模拟中,个体通常被视为对环境刺激作出即时响应的决策单元,缺乏对意图生成与演化过程的刻画。为此,本文创新性地将城市人群移动行为建模为包含认知推理层的 Agent 决策过程,将出行决策划分为经验驱动与推理驱动的双层意图生成机制。通过引入人类偏好优化算法对大语言模型进行对齐,使 Agent 在不同情境复杂度下自适应选择认知路径,并生成结构化意图推理链,从而提升了移动行为模拟的认知合理性与稳定性。

(2) 提出了基于意图演化的群体移动涌现机制分析方法针对宏观出行现象难以追溯微观成因的问题,本文构建了基于个体意图聚类与时序转移建模的群体分析框架。通过对群体中个体意图状态进行抽象表示,并采用马尔可夫过程刻画意

图状态转移规律，建立微观认知变化与宏观群体移动模式之间的动态映射关系。实验分析表明，该方法能够有效揭示交通拥堵、行为同质化以及平台竞争加剧等现象背后的意图驱动机制，实现从现象描述到机制解释的跨尺度分析。

6.2 展望

尽管本文在意图驱动的移动行为模拟与机制分析方面进行了系统探索，但仍存在一定局限性，有待在后续研究中进一步完善。

(1) 意图表示形式仍有提升空间。当前意图主要以结构化文本及嵌入向量形式进行建模，其表达能力依赖于大语言模型的语义编码质量。尽管实验结果表明该表示方式能够有效支持聚类与演化分析，但在复杂社会规范、多目标权衡及群体博弈等场景中，意图的层级结构与因果依赖关系仍未被显式刻画。未来可结合符号逻辑表示、因果图模型或知识图谱结构，对意图进行更具层次性与可组合性的表达，从而提升机制分析的精细度。

(2) 群体交互建模仍偏向间接表达。本文主要通过意图状态的聚合与转移分析刻画群体层面的演化规律，但 Agent 之间的直接博弈与策略协同机制尚未进行显式建模。未来可引入多智能体强化学习或博弈论框架，将意图状态与策略更新过程耦合，构建更完整的群体交互动态模型，以揭示竞争、协作与反馈机制对涌现结构的影响。

(4) 意图生成与真实人类决策的一致性仍需进一步验证。虽然本文通过偏好优化方法对模型进行了对齐，但缺乏基于问卷调查或真实行为实验的独立认知验证数据。未来可结合行为实验与心理测量方法，对模型生成的意图推理链进行定量评估，从而增强模型的认知可信度。

展望未来，随着大语言模型、多智能体系统与复杂网络分析技术的持续发展，将认知建模、计算实验与社会系统分析相结合，构建具备可解释性与可干预能力的群体智能系统，将成为城市计算与复杂系统研究的重要方向。围绕意图演化、策略协同与群体结构自组织等问题展开深入研究，有望为城市交通治理、公共资源调度与社会风险预警提供更加科学与可解释的决策支持工具。

参考文献

- [1] Kahneman D. Thinking, fast and slow [M]. macmillan, 2011.
- [2] Verplanken B, Aarts H, Van Knippenberg A. Habit, information acquisition, and the process of making travel mode choices [J]. *European journal of social psychology*, 1997, 27 (5): 539–560.
- [3] Helbing D, Molnar P. Social force model for pedestrian dynamics [J]. *Physical review E*, 1995, 51 (5): 4282.
- [4] Wiest J, Höffken M, Kreßel U, et al. Probabilistic trajectory prediction with Gaussian mixture models [C]. In *2012 IEEE Intelligent vehicles symposium*, 2012: 141–146.
- [5] Wang J M, Fleet D J, Hertzmann A. Gaussian process dynamical models for human motion [J]. *IEEE transactions on pattern analysis and machine intelligence*, 2007, 30 (2): 283–298.
- [6] Hochreiter S, Schmidhuber J. Long short-term memory [J]. *Neural computation*, 1997, 9 (8): 1735–1780.
- [7] Alahi A, Goel K, Ramanathan V, et al. Social lstm: Human trajectory prediction in crowded spaces [C]. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016: 961–971.
- [8] Xue H, Huynh D Q, Reynolds M. SS-LSTM: A hierarchical LSTM model for pedestrian trajectory prediction [C]. In *2018 IEEE winter conference on applications of computer vision (WACV)*, 2018: 1186–1194.
- [9] Zhang P, Ouyang W, Zhang P, et al. Sr-lstm: State refinement for lstm towards pedestrian trajectory prediction [C]. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2019: 12085–12094.
- [10] Liu X, Chen H, Andris C. trajGANs: Using generative adversarial networks for geo-privacy protection of trajectory data (Vision paper) [C]. In *Location privacy and security workshop*, 2018: 1–7.
- [11] Rao J, Gao S, Kang Y, et al. LSTM-TrajGAN: A deep learning approach to trajectory privacy protection [J]. *arXiv preprint arXiv:2006.10521*, 2020.
- [12] Choi S, Kim J, Yeo H. TrajGAIL: Generating urban vehicle trajectories using generative adversarial imitation learning [J]. *Transportation Research Part C: Emerging Technologies*, 2021, 128: 103091.
- [13] Ivanovic B, Pavone M. The trajectron: Probabilistic multi-agent trajectory modeling with dynamic spatiotemporal graphs [C]. In *Proceedings of the IEEE/CVF international conference on computer vision*, 2019: 2375–2384.

- [14] Zhang Z, Chen N, Zhang X, et al. Traj-Transformer: Diffusion Models with Transformer for GPS Trajectory Generation [J]. arXiv preprint arXiv:2510.06291, 2025.
- [15] Shi L, Wang L, Zhou S, et al. Trajectory unified transformer for pedestrian trajectory prediction [C]. In Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 9675–9684.
- [16] Xue H, Voutharoja B P, Salim F D. Leveraging language foundation models for human mobility forecasting [C]. In Proceedings of the 30th international conference on advances in geographic information systems, 2022: 1–9.
- [17] Park J S, O’Brien J, Cai C J, et al. Generative agents: Interactive simulacra of human behavior [C]. In Proceedings of the 36th annual acm symposium on user interface software and technology, 2023: 1–22.
- [18] Li Z, Xia L, Tang J, et al. Urbangpt: Spatio-temporal large language models [C]. In Proceedings of the 30th ACM SIGKDD conference on knowledge discovery and data mining, 2024: 5351–5362.
- [19] Jin M, Wang S, Ma L, et al. Time-llm: Time series forecasting by reprogramming large language models [J]. arXiv preprint arXiv:2310.01728, 2023.
- [20] Gong L, Lin Y, Zhang X, et al. Mobility-llm: Learning visiting intentions and travel preference from human mobility data with large language models [J]. Advances in Neural Information Processing Systems, 2024, 37: 36185–36217.
- [21] Shao C, Xu F, Fan B, et al. Chain-of-Planned-Behaviour Workflow Elicits Few-Shot Mobility Generation in LLMs. 2024. <https://arxiv.org/abs/2402.09836>.
- [22] Ge S, Ye P, Zhang R, et al. Llm-driven cognitive modeling for personalized travel generation [J]. IEEE Transactions on Computational Social Systems, 2025.
- [23] Fromm J. The emergence of complexity [M]. Kassel university press Kassel, 2004.
- [24] Helbing D, Farkas I, Vicsek T. Simulating dynamical features of escape panic [J]. Nature, 2000, 407 (6803): 487–490.
- [25] Helbing D, Farkas I, Vicsek T. Freezing by heating in a driven mesoscopic system [J]. Physical Review Letters, 2000, 84 (6): 1240–1243.
- [26] Zheng Y, Capra L, Wolfson O, et al. Urban computing: concepts, methodologies, and applications [J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2014, 5 (3): 1–55.
- [27] Schor J B, Attwood-Charles W, Cansoy M, et al. Dependence and precarity in the platform economy [J]. Theory and society, 2020, 49 (5): 833–861.
- [28] Kerner B S, Rehborn H. Experimental features and characteristics of traffic jams [J]. Physical review E, 1996, 53 (2): R1297.

- [29] Guimera R, Mossa S, Turttschi A, et al. The worldwide air transportation network: Anomalous centrality, community structure, and cities' global roles [J]. *Proceedings of the National Academy of Sciences*, 2005, 102 (22): 7794–7799.
- [30] Fan R, Yao Q, Chen R, et al. Agent-based simulation model of panic buying behavior in urban public crisis events: A social network perspective [J]. *Sustainable Cities and Society*, 2024, 100: 105002.
- [31] Nagel K, Rickert M. Parallel implementation of the TRANSIMS micro-simulation [J]. *Parallel Computing*, 2001, 27 (12): 1611–1639.
- [32] Batty M. Cities and complexity: understanding cities with cellular automata, agent-based models, and fractals [M]. The MIT press, 2007.
- [33] Zhang L, Luo S, Xia H. An investigation of intra-Urban mobility pattern of taxi passengers [J]. *arXiv preprint arXiv:1612.08378*, 2016.
- [34] Rong C, Ding J, Li Y. An interdisciplinary survey on origin-destination flows modeling: Theory and techniques [J]. *ACM Computing Surveys*, 2024, 57 (1): 1–49.
- [35] Kahn H, Wiener A J. The next thirty-three years: A framework for speculation [J]. *Daedalus*, 1967: 705–732.
- [36] 李大宇, 米加宁, 徐磊. 公共政策仿真方法: 原理, 应用与前景 [J]. *公共管理学报*, 2011, 8 (4): 8–20.
- [37] 薛霄, 于湘凝, 周德雨, et al. 计算实验方法的溯源, 现状与展望 [J]. *自动化学报*, 2023, 49 (2): 246–271.
- [38] Li L, Huang W-L, Liu Y, et al. Intelligence testing for autonomous vehicles: A new approach [J]. *IEEE Transactions on Intelligent Vehicles*, 2016, 1 (2): 158–166.
- [39] Acevedo M F, Callicott J B, Monticino M, et al. Models of natural and human dynamics in forest landscapes: Cross-site and cross-cultural synthesis [J]. *Geoforum*, 2008, 39 (2): 846–866.
- [40] Payne K. AI Arms and Influence: Frontier Models Exhibit Sophisticated Reasoning in Simulated Nuclear Crises [J]. *arXiv preprint arXiv:2602.14740*, 2026.
- [41] Song C, Koren T, Wang P, et al. Modelling the scaling properties of human mobility [J]. *Nature physics*, 2010, 6 (10): 818–823.
- [42] Krumm J, Horvitz E, et al. Locadio: Inferring motion and location from wi-fi signal strengths. [C]. In *mobiquitous*, 2004: 4–13.
- [43] Raney B, Cetin N, Völlmy A, et al. An agent-based microsimulation model of Swiss travel: First results [J]. *Networks and Spatial Economics*, 2003, 3 (1): 23–41.
- [44] Yuan J, Zheng Y, Xie X. Discovering regions of different functions in a city using human mobility and POIs [C]. In *Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining*, 2012: 186–194.

- [45] Huang D, Song X, Fan Z, et al. A variational autoencoder based generative model of urban human mobility [C]. In 2019 IEEE conference on multimedia information processing and retrieval (MIPR), 2019: 425–430.
- [46] Feng J, Yang Z, Xu F, et al. Learning to simulate human mobility [C]. In Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining, 2020: 3426–3433.
- [47] Cao C, Li M. Generating mobility trajectories with retained data utility [C]. In Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining, 2021: 2610–2620.
- [48] Rao A S, Georgeff M P, et al. BDI agents: from theory to practice. [C]. In Icmas, 1995: 312–319.
- [49] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models [J]. Advances in neural information processing systems, 2022, 35: 24824–24837.
- [50] Yao S, Zhao J, Yu D, et al. React: Synergizing reasoning and acting in language models [C]. In The eleventh international conference on learning representations, 2022.
- [51] Moussaïd M, Perozo N, Garnier S, et al. The walking behaviour of pedestrian social groups and its impact on crowd dynamics [J]. PLoS ONE, 2010, 5 (4): e10047.
- [52] Goldstein J. Emergence as a construct: History and issues [J]. Emergence, 1999, 1 (1): 49–72.
- [53] De Wolf T, Holvoet T. Emergence versus self-organisation: Different concepts but promising when combined [C]. In International workshop on engineering self-organising applications, 2004: 1–15.
- [54] Devlin J, Chang M-W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding [C]. In Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers), 2019: 4171–4186.
- [55] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.
- [56] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners [J]. Advances in neural information processing systems, 2020, 33: 1877–1901.
- [57] Howard J, Ruder S. Universal language model fine-tuning for text classification [C]. In Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2018: 328–339.
- [58] Houshy N, Giurgiu A, Jastrzebski S, et al. Parameter-efficient transfer learning for NLP [C]. In International conference on machine learning, 2019: 2790–2799.
- [59] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models. [J]. Iclr, 2022, 1 (2): 3.

-
- [60] Dettmers T, Pagnoni A, Holtzman A, et al. Qlora: Efficient finetuning of quantized llms [J]. *Advances in neural information processing systems*, 2023, 36: 10088–10115.
 - [61] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model [J]. *Advances in neural information processing systems*, 2023, 36: 53728–53741.
 - [62] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback [J]. *Advances in neural information processing systems*, 2022, 35: 27730–27744.
 - [63] Wang J, Jiang R, Yang C, et al. Large language models as urban residents: An llm agent framework for personal mobility generation [J]. *Advances in Neural Information Processing Systems*, 2024, 37: 124547–124574.
 - [64] Wongso W, Xue H, Salim F D. Massive-STEPS: Massive Semantic Trajectories for Understanding POI Check-ins – Dataset and Benchmarks. 2025. <https://arxiv.org/abs/2505.11239>.
 - [65] Feng J, Li Y, Zhang C, et al. Deepmove: Predicting human mobility with attentional recurrent networks [C]. In *Proceedings of the 2018 world wide web conference*, 2018: 1459–1468.

发表论文和参加科研情况说明

(一) 发表的学术论文

- [1] XXX, XXX. Density and Non-Grid based Subspace Clustering via Kernel Density Estimation[C]. ECML-PKDD 2012, Bristol, UK.(Submitted, Under review)
- [2] XXX, XXX. A tree parent storage based on hashtable for XML construction[C]. Communication Systems, Networks and Applications, Hongkong, 2010: 325-328. (EI DOI: 10.1109/ICCSNA.2010.5588732)

(二) 申请及已获得的专利（无专利时此项不必列出）

- [1] XXX, XXX. XXXXXXXXXXX: 中国, 1234567.8[P]. 2012-04-25.

(三) 参与的科研项目

- [1] XXX, XXX. XX 信息管理与信息系统, 国家自然科学基金项目. 课题编号: XXXX.

致 谢

时间如白驹过隙，转眼间三年的研究生生涯即将画上句号。仿佛昨日才踏入校园，而今已站在毕业的节点，准备迎接新的征程。心中虽有不舍，但更多的是感恩与从容。在论文完成之际，谨向所有在此过程中给予我关心、指导与帮助的人，致以最诚挚的感谢。

首先，衷心感谢我的导师薛霄教授，以及实验室的师兄师姐们。在科研探索的道路上，薛霄老师以严谨的治学态度和深厚的学术素养为我指引方向。从课题构思、方法设计到论文撰写，每一个关键阶段都离不开老师耐心细致的指导与启发，使我在学术训练中逐渐形成规范的研究思维与独立分析能力。师兄师姐们在科研讨论中的分享与建议，也让我在遇到困惑时获得启发与支持。感谢实验室的同门与朋友们，我们在交流与合作中共同进步，在相互鼓励中坚定前行，这段同行的时光将成为难忘的记忆。

其次，最深的感谢献给我的父母。多年来，他们始终尊重并支持我的每一个选择，在人生的重要阶段给予我理性的建议与坚定的信任。无论顺境或挫折，他们始终给予我理解与鼓励，使我能够专注于学业与研究，无后顾之忧。家人的支持与陪伴，是我不断前行的重要力量。

同时，也感谢一路以来始终努力坚持的自己。离乡求学的岁月里，曾有迷茫与压力，也有反思与成长。但正是这些经历，使我更加坚定地面对挑战，踏实走好每一步。未来的道路仍然漫长，我将继续保持初心，认真对待每一次选择与机会。

最后，感谢各位专家和老师百忙之中审阅本论文，并提出宝贵的意见与建议。谨致以诚挚的敬意与谢意。